



第二次学习总结

From a Social Cognitive Perspective: Context-aware
Visual Social Relationship Recognition

汇报: *yixuan*

日期: 2025.3.24


目录

CONTENTS

01 论文精读收获

03 数据集介绍

02 深度学习应用



论文精读收获

✦ 专有名词解析

Phase work overview

多模态侧适配器网络 (MSAT)

多模态：指的是同时处理视觉（图像）和语言（文本）两种模态。

侧适配器网络：是一种轻量级的神经网络模块，附加在预训练模型（如 CLIP）的旁边，用于调整预训练模型的输出，使其更适合特定任务。

MSAT 的作用：

- 将 CLIP 的视觉和语言语义知识迁移到社会关系识别任务中。
- 避免完全微调 CLIP 模型，从而节省计算资源并减少过拟合风险。

CLIP：对比语言-图像预训练，它旨在同时理解图像和文本，使其能够执行各种任务。

COCO数据集：上下文中的常见物体，是一个用于计算机视觉中的物体检测、分割和描述任务的**大规模数据集**。它包含复杂日常场景的图像，并对物体、其位置和关系进行了注释。

自上而下的注意机制：用于引导模型关注输入数据中的重要部分。与自下而上的注意机制（Bottom-up Attention）不同，自上而下的注意机制是**基于任务目标或高层语义信息来动态调整注意力**的，从而更灵活地捕捉与任务相关的上下文信息。

（举例：你带着一个明确的目标去看照片，比如“找找看有没有家庭聚会的线索”。这时你会特别关注一些细节，比如：

- 有没有婚礼戒指？
- 有没有拥抱或亲密的动作？
- 场景是不是在家里或者节日聚会上？

这种“带着目标去看照片”的方式，就是“自上而下的注意机制”。

✦ 专有名词解析

Phase work overview


多头自注意力 (MSA) : 多头即指同时计算个注意力分布，每个注意力头关注输入序列的不同部分，从而捕捉更丰富的信息或是更好地捕捉复杂的依赖关系。

交叉注意机制 (Cross-Attention Mechanism) 一种用于处理多模态数据（如图像和文本）的注意力机制。它的核心思想是通过一个模态的查询 (Query) 与另一个模态的键 (Key) 和值 (Value) 进行交互，从而捕捉两个模态之间的相关性。交叉注意力机制广泛应用于多模态任务中，如图像 - 文本匹配、视觉问答和多模态融合。交叉注意力机制是自注意力机制 (Self-Attention) 的扩展。自注意力机制用于捕捉单个模态内部的依赖关系，而交叉注意力机制用于捕捉两个模态之间的依赖关系。

✦
消融研究 (Ablation Study) : 是机器学习和深度学习领域中一种重要的实验方法，用于评估模型中各个组件或特征对最终性能的贡献。通过逐步移除或禁用模型的某些部分，帮助研究人员理解每个组件的作用，并确定哪些部分对模型的性能至关重要。本文用来验证ConSoR框架中每个模块的贡献。

视觉语言对比 (Visual-Language Contrastive Learning) : ✦一种多模态学习方法，旨在通过对比学习的方式，将视觉信息（如图像）和语言信息（如文本）进行对齐和融合。这种方法的核心思想是通过最大化正样本对的相似性，同时最小化负样本对的相似性，从而学习到视觉和语言之间的联合表示。


上下文人际推理模块 (CIR)



14 x 14 patches ↓



Social-aware Context patches
(attend 'holding hands' in free-form way)



1.提取图像中的视觉信息并转化为词汇提示

Step 1: Visual-vocabs prompt construction

2.用零-shot的方式从每个语料库中选择最相关的(前5个)视觉词汇

Step 2:

3.生成几个候选的提示性语言

Step 3: Social prompt construction

4.进一步视觉-语言对比, 筛选couple

V-L Contrasting Classification

模板

· The photo is taken in $[v_i^{SC}]$

场景类别

场景属性

The scene attribute of the image is $[v_i^{SA}]$

· There are $[v_i^{OC}]$ in the photo.

物体类别

· The emotion in this photo is $[v_i^E]$.

情绪



v_i from Social-relevant Contextual Corpora



Input Image

CLIP Model
Cosine Similarity

CLIP双编码器编码和余弦相似度进一步筛选词汇

Candidate labels: *Friend, Family, Couple, Professional, Commercial, No relation*

Apply

· Candidate SP#1: In this photo, the social relation of this person pair is **Friend**. The photo is taken in *harbor, islet, ...* The scene attribute of the image is *ocean, flowers, ...* There are *groom, bridegroom, ...* in the photo. The emotion in this photo is *acceptance*.

· Candidate SP#2: In this photo, the social relation of this person pair is **Family**. ...
...(same with candidate SP#1 except relation)

· Candidate SP#6: In this photo, the social relation of this person pair is **No relation**. ...

ConSoR
Linguistic branch



ConSoR
Visual branch


T_1	$I \cdot T_1$
T_2	$I \cdot T_2$
T_3	$I \cdot T_3$
T_4	$I \cdot T_4$
T_5	$I \cdot T_5$
T_6	$I \cdot T_6$

Predict "Couple"

语料库




Corpora	#words	Examples
Scene Category [62]	365	movie theater, classroom, office
Scene Attribute [62]	94	sports, shopping, playing, camping
Object Category [63]	1000	bow-tie, rubber, shopping basket
Emotion Category [64]	24	joy, trust, interest, grief, surprise

emotion category情绪轮



V-L: 计算图像特征与所有候选社交提示的相似度, 通过交叉熵损失优化。强化模型对社交关键上下文的敏感性 (“玫瑰花”对“情侣”关系的贡献度高于“同事”等)。

图5. 对于PISC-Fine数据集的ConSoR的消融实验。在图5a中, ConR、IntR、GCF代表上下文推理、人际推理和全局上下文。融汇n在CIR模块中。在图5b中, SC、SA、OC、E分别表示场景类别、场景属性、对象类别和情感语料库。



人际和上下文推理
显著提升了模型的性能

丰富社交相关内容的
语料提升了性能。这一改善归因于描述图像的社交提示的语义精确度提高, 这更有效地引导模型通过后续的视觉语言对比识别社交决定性线索。

ConSoR的性能随着
主干的扩展而增强。更大的主干包含更多的语义知识, 突显了ConSoR出色的可扩展性。

TABLE III
EXPERIMENTAL RESULTS ON PISC AND PIPA DATASET. WE OUTPERFORM SOTA METHODS BY ACHIEVING **+12.2 mAP** IMPROVEMENT ON THE PISC-FINE DATASET, WHICH IS CONSIDERED THE PRIMARY METRIC FOR EVALUATING VISUAL SOCIAL RELATION RECOGNITION TASK. (INT.: INTIMATE, NON.: NON-INTIMATE, NOR.: NO RELATION, FRI.: FRIEND, FAM.: FAMILY, COU.: COUPLE, PRO.: PROFESSIONAL, COM.: COMMERCIAL.) THE PIPA-COARSE/PIPA-FINE DATASET IS 5/16-CLASS CLASSIFICATION, RESPECTIVELY.

Methods	PISC Coarse				PISC Fine							PIPA Coarse	PIPA Fine
	Int.	Non.	NoR.	mAP	Fri.	Fam.	Cou.	Pro.	Com.	NoR.	mAP	Acc@1	Acc@1
Pair-Box-CNN [13]	70.3	80.5	38.8	65.1	30.2	59.1	69.4	57.5	41.9	34.2	48.2	65.9	58.0
Dual-Glance [13]	73.1	84.2	59.6	79.7	35.4	68.1	76.3	70.3	57.6	60.9	63.2	-	59.6
GRM [14]	81.7	73.4	65.5	82.8	59.6	64.4	58.6	76.6	39.5	67.7	68.7	-	62.3
MGR [34]	-	-	-	-	64.6	67.8	60.5	76.8	34.7	70.4	70.0	-	64.4
SRG-GN [37]	-	-	-	-	25.2	80.0	100.0	78.4	83.3	62.5	71.6	-	53.6
GR ² N [15]	81.6	74.3	70.8	83.1	60.8	65.9	84.8	73.0	51.7	70.4	72.7	72.3	64.3
HF-SRGR [36]	89.1	87.0	75.5	84.6	82.2	39.4	33.2	60.0	47.7	71.8	73.3	-	65.9
GA-GCN [40]	87.3	86.0	89.8	87.7	63.1	73.5	78.3	82.7	76.8	71.8	73.6	-	66.6
SRR-LGR [41]	89.6	84.6	78.5	84.8	83.9	52.4	35.9	64.0	54.0	63.6	73.0	-	66.1
PRM [39]	-	-	-	-	56.5	70.8	72.3	78.5	81.4	68.3	73.2	73.2	65.6
ConSoR (Ours)	91.3	78.7	71.0	90.2 (+2.5)	80.9	80.2	75.8	90.4	45.2	76.1	85.8 (+12.2)	82.4 (+9.2)	76.4 (+9.8)

将ConSoR与以下方法进行比较：Pair-Box-CNN 、Dual-Glance、 GRM、MGR 、SRG-GN 、GR2N HF-SRGR、GA-GCN、SRR-LGR、PRM。

结合CLIP模型的丰富语义以及通过视觉-语言方法促使模型关注关键的社会决定性上下文，ConSoR显著超过了之前的方法，在PISC-Fine数据集上实现了+12.2 mAP的提升，该数据集被认为是社会关系识别任务中的公认主要设置。



TABLE IV

COMPARISON WITH CONSoR VARIANTS. WE PERFORMED ABLATIONS FIVE TIMES AND CONDUCTED T-TESTS BETWEEN EACH ABLATION AND CONSoR. THE RESULTS INDICATE THAT CONSoR IS STATISTICALLY SIGNIFICANTLY SUPERIOR IN MOST CASES.

Methods	PISC (mAP)				PIPA (Acc@1)			
	Coarse		Fine		Coarse		Fine	
	mean & std.	p-value	mean & std.	p-value	mean & std.	p-value	mean & std.	p-value
CLIP-ZeroShot	36.20±.00	10 ⁻¹¹	30.40±.00	10 ⁻⁹	34.80±.00	10 ⁻⁹	39.00±.00	10 ⁻⁷
CLIP-Frozen	86.60±.21	10 ⁻⁹	77.72±.61	10 ⁻⁸	78.72±.54	10 ⁻⁵	73.36±.43	0.003
CLIP-Finetune	88.22±.26	10 ⁻⁶	82.08±.40	10 ⁻⁶	77.82±.67	10 ⁻⁶	73.00±.37	0.002
ConSoR-Visual	90.34±.30	0.109	84.62±.45	0.094	82.38±.54	0.877	75.84±.36	0.389
ConSoR-ObjDet	89.94±.25	0.513	84.76±.66	0.274	81.28±.57	0.017	76.24±1.21	0.860
ConSoR	90.24±.21	-	85.80±.51	-	82.44±.64	-	76.38±1.22	-

为了验证我们ConSoR框架中每个模块的贡献，我们进一步设计了多个变体以及消融以对我们的主要数据集（即PISC-Fine数据集）进行消融研究。

另外，如表V所示，ConSoR在性能和计算复杂性、效率之间达到了最佳平衡。

1. mean（均值±标准差）

均值（mean）：模型在多次实验中的平均性能（如mAP）。均值越高，模型越优。

标准差（std.）：多次实验结果的波动范围，反映模型的稳定性。标准差小（如ConSoR的±0.51）说明模型鲁棒性强，受随机因素影响小。

2. p值（p-value）

表示当前方法与ConSoR（基准）的差异是否由随机误差导致。

p值越小 → 原假设越不可信，说明差异越可能是真实的。

p值越大 → 差异可能只是随机波动。

如：如果仅看均值，ConSoR-Visual（84.62）和ConSoR（85.80）似乎有差异，但p=0.094说明这个差异可能不可靠。

TABLE V

EFFICIENCY ANALYSIS OF CONSoR VARIANTS. ALL EXPERIMENTS WERE CONDUCTED USING TWO NVIDIA GeForce RTX 3090 Ti GPUs WITH 16 BATCH-SIZE. CONSoR STRIKES A GOOD BALANCE BETWEEN PERFORMANCE AND COMPLEXITY/EFFICIENCY

Methods	Train.Params.(M)	TotalParams.(M)	GPUMem.(MB/GPU)
CLIP-ZeroShot	0	149	1,628
CLIP-Frozen	7.6	157	2,256
CLIP-Finetune	157	157	5,706
ConSoR-Visual	19.4	105	2,760
ConSoR-ObjDet	20	214	4,535
ConSoR	20	170	3,554



TABLE VI

ABLATIONS ON MSAT MODULES. THE INCORPORATION OF MSAT EFFECTIVELY MITIGATES SEVERE OVERFITTING ISSUES AND ENHANCES EFFICIENCY.

Methods	PISC (mAP)		PIPA (Acc@1)		Trainable Params. (Million)	GPU Memory (MB/GPU)
	Coarse	Fine	Coarse	Fine		
ConSoR-Visual w/o MSAT	89.36±.37	83.58±.42	78.10±.33	72.98±.70	102	5,898
ConSoR-V	90.34±.30	84.62±.45	82.38±.54	75.84±.36	19.4	2,760
ConSoR w/o MSAT	66.94±2.72	57.32±3.53	66.46±1.66	60.88±2.97	166	9,596
ConSoR	90.24±.21	85.80±.51	82.44±.64	76.38±1.22	20	3,554

表格介绍：

ConSoR-Visual w/o MSAT

→ 仅使用视觉分支（Visual），不包含多模态侧适配器（MSAT）。

ConSoR w/o MSAT

→ 完整多模态模型（视觉+语言），但不包含MSAT（直接微调CLIP，未使用轻量适配器）。

PISC (mAP) 和 PIPA (Acc@1)：这些是模型在测试集上的性能指标，分别表示平均精度（mAP）和 top-1 准确率（Acc@1）。

Trainable Params. (Million)：模型的可训练参数数量，反映了模型的复杂度。

GPU Memory (MB/GPU)：模型训练时占用的 GPU 内存（显存），反映了模型的资源消耗。

可见：MSAT的引入不仅通过缓解与直接将CLIP模型作为较小数据集的编码器应用相关的严重过拟合问题来增强性能，而且还显著提高了模型的效率。



TABLE VIII
ABLATION STUDY OF DIFFERENT FUSION STRATEGIES FOR MSAT ON
PISC-FINE DATASET. EACH FUSION LAYER CONTAINS THE TEXT AND
VISUAL FEATURES SPECIFIC TO ITS CORRESPONDING LAYER.

Strategies	Fusion Layers	mAP
w/o fusion	-	79.8
Single-layer Fusion	0th layer	80.2
	3rd layer	81.7
	6th layer	82.6
	9th layer	83.5
	12th layer	84.1
Multi-layers Fusion	(9,12)-layers	85.1
	(6,9,12)-layers	85.5
	(3,6,9,12)-layers	85.6
	(0,3,6,9,12)-layers	85.8

为了进一步检查融合策略在MSAT中的有效性，进行了各种融合策略的消融研究，如表 VIII 所示，可见，融入CLIP特征可以显著提升性能，集成更多层次会导致结果的改善。此外，融入MSAT的信息层次越深，其性能就越好，因为更深的特征包含更多的高层次语义信息。



策略类型	代表层	mAP	语义层级	适用场景
无融合	-	79.8	无外部知识	基线对比
单层（低）	0th, 3rd	80-82	低级特征（纹理、边缘）	简单动作（如“站立”）
单层（高）	9th, 12th	83-84	高级语义（场景、关系）	复杂关系（如“婚礼中的夫妻”）
多层	(6,9,12)-layers	85.5	多粒度融合	综合推理（动作+场景+物体）




(a) SP.: ... 这张照片中有麦克风... 这张照片展示了观众场景...




(b) SP.: ... 这张照片中有理发椅和手持吹风机……这张照片的背景是美容院……




(c) SP.: ... 这张照片中有杂货店... 这张照片展示了购物和商业活动的场景...



(d) SP.: ... 这张照片的背景是海岸、沙滩和挖掘... 这张照片展示了挖掘和海洋场景...



(e) SP.: ... 这张照片里有一把铲子。整张照片的背景是一个施工现场。这张照片展示了挖掘场景...



(f) SP.: ... 这张照片中有海军服和军服……这张照片的背景是厨房……(有)生活方式: ... 这张照片中有麦克风……这张照片展示了社交场景。这张照片传达了期待的情感。




(r) CMI: ... 这张照片中有海军服



(h) SP.: ... 这张照片的背景是酒吧。这张照片展示了社交场景。这张照片展现了期待的情感。

图6. 在PISC-Fine数据集上ConSoR的可视化案例。绿色、蓝色和红色的文本分别代表真实值、正确预测和错误预测。SP. 表示社交提示。最佳观看效果为彩色。



深度学习应用

✦ 工作成果展示

梯度下降 (Gradient Descent)： 优化神经网络的核心算法，用于更新模型参数以最小化损失函数。

AdamW 优化器 一种基于梯度下降的优化算法，结合了动量和自适应学习率的特性。AdamW 通过计算损失函数对模型参数的梯度，逐步更新参数，使模型在训练过程中逐渐收敛。

CosineAnnealing 学习率调度器 一种学习率调度策略，用于在训练深度学习模型时动态调整学习率。核心思想是通过余弦函数周期性地调整学习率，从而帮助模型跳出局部最优解，并在训练过程中更好地收敛。通常与梯度下降结合使用。

MSAT模块中，梯度下降用于更新以下参数：

- **门控机制**的参数，参数需要通过梯度下降进行优化，以使模型能够动态调整特征融合的比例。
- **多头自注意力机制 (MSA)** 的参数，需要通过梯度下降进行优化，以捕捉视觉和语言特征之间的关系。

Implementation Details. We leverage AdamW [65] as the optimizer. We set the learning rate of all trainable parameters to 10^{-4} , weight decay to 0.05, training epoch to 6, batch size to 32. We utilize CosineAnnealing learning rate schedule to adjust the learning rate. We adopt the pre-trained CLIP ViT-B/16 [18] as vision encoder and the input images are resized to 224×224 . For MSAT, we set the transformer to 4 layers, the number of heads to 6, the dimension of transformer layers to 192, the patch size to 16, and temperature $\tau = 0.1$ in MSAT. We set the transformer layer number of interpersonal reasoning and contextual reasoning to 1 by default and the number of heads to 8.

in intermediate CLIP visual feature into the j -th layer of our side adapter network via the gated mechanism as follows:

$$\hat{\mathcal{V}}_j^{SN} = \mu_j^v \mathcal{V}_j^{SN} + (1 - \mu_j^v) \mathcal{V}_i^{CLIP}, \quad (1)$$

$$\mu_j^v = \text{sigmoid}\left(\frac{\alpha_j^v}{\tau}\right), \quad (2)$$

where α_j^v is a learnable gate scalar for the visual branch and τ is temperature. Similarly, we fuse the latent linguistic

knowledge from CLIP into our side adapter network.

$$\hat{\mathcal{T}}_j^{SN} = \mu_j^t \mathcal{T}_j^{SN} + (1 - \mu_j^t) \mathcal{T}_i^{CLIP}, \quad (3)$$

$$\mu_j^t = \text{sigmoid}\left(\frac{\alpha_j^t}{\tau}\right), \quad (4)$$

where α_j^t is a learnable gate scalar for the linguistic branch.

self-attention (MSA) layers [59], to obtain the representation of the image $\mathcal{V}^{SN} \in \mathbb{R}^{L^v \times r}$ and the feature of the corresponding social prompt $\mathcal{T}^{SN} \in \mathbb{R}^{L^t \times r}$ as follows,

$$\mathcal{V}_{j+1}^{SN} = \text{MSA}(\hat{\mathcal{V}}_j^{SN}) \quad (5)$$

$$\mathcal{T}_{j+1}^{SN} = \text{MSA}(\hat{\mathcal{T}}_j^{SN}) \quad (6)$$

By sharing parameters between the visual and linguistic spaces, the multi-modal side adapter network learns representations that are more semantically aligned across modalities, which significantly enhances the performance on this task.

✦ 工作成果展示

交叉熵损失（Cross-Entropy Loss）： 交叉熵损失是分类任务中常用的损失函数，用于衡量模型预测概率分布与真实标签之间的差异。

视觉-语言对比分类 使用交叉熵损失来计算模型预测的社会关系与真实标签之间的差异。

激活函数（Activation Functions）： 神经网络中的一种关键组件，用于引入非线性，使神经网络能够学习和表示复杂的模式。如果没有激活函数，神经网络将只是一个线性模型，无法捕捉数据中的非线性关系。激活函数的作用是将输入信号转换为输出信号，通常用于神经元的输出。

Sigmoid 函数

门控机制中，Sigmoid 函数用于生成门控权重。Sigmoid 函数将输入映射到 (0, 1) 之间，用于控制视觉和语言特征的融合比例。

Softmax 函数

视觉-语言对比分类中，Softmax函数用于将余弦相似度转换为概率分布。Softmax函数将输入向量转换为概率分布，用于多分类任务。

we compute the cosine similarity between the individual-pair feature and all candidate social prompts features. Then, we apply softmax activation to compute the cross-entropy loss as follows, The loss for ConSoR can be written as:

$$\mathbf{z} = [\text{sim}(\mathbf{T}_{r_1}^{sp}, \mathbf{U}), \dots, \text{sim}(\mathbf{T}_{r_C}^{sp}, \mathbf{U})] \quad (13)$$

$$L_{ConSoR} = L_{CE}(\text{softmax}(\mathbf{z}), y_u) \quad (14)$$

where $\text{sim}(a, b) = a^\top b / (\|a\| \|b\|)$, y_u denotes the social relation label of the individual-pair, and the L_{CE} is the cross entropy loss. By employing a visual-linguistic contrasting classification paradigm, ConSoR is able to adaptively and thoroughly investigate the crucial, social-decisive contexts.

we fuse the visual feature into the j -th layer of our side adapter network via the gated mechanism as follows:

$$\hat{\mathcal{V}}_j^{SN} = \mu_j^v \mathcal{V}_j^{SN} + (1 - \mu_j^v) \mathcal{V}_i^{CLIP}, \quad (1)$$

$$\mu_j^v = \text{sigmoid}(\frac{\alpha_j^v}{\tau}), \quad (2)$$

where α_j^v is a learnable gate scalar for the visual branch and τ is temperature. Similarly, we fuse the latent linguistic

$$\hat{\mathcal{T}}_j^{SN} = \mu_j^t \mathcal{T}_j^{SN} + (1 - \mu_j^t) \mathcal{T}_i^{CLIP}, \quad (3)$$

$$\mu_j^t = \text{sigmoid}(\frac{\alpha_j^t}{\tau}), \quad (4)$$

where α_j^t is a learnable gate scalar for the linguistic branch.

apply softmax activation to compute the cross-entropy loss as follows, The loss for ConSoR can be written as:

$$\mathbf{z} = [\text{sim}(\mathbf{T}_{r_1}^{sp}, \mathbf{U}), \dots, \text{sim}(\mathbf{T}_{r_C}^{sp}, \mathbf{U})] \quad (13)$$

$$L_{ConSoR} = L_{CE}(\text{softmax}(\mathbf{z}), y_u) \quad (14)$$

where $\text{sim}(a, b) = a^\top b / (\|a\| \|b\|)$, y_u denotes the social relation label of the individual-pair, and the L_{CE} is the cross

✦ 工作成果展示

卷积操作 (Convolution Operation) : 卷积操作是卷积神经网络的核心，用于提取图像的局部特征。

人际推理模块中，ROIAlign 操作基于卷积特征图提取特定区域的特征。ROIAlign 是 Faster R-CNN 和 Mask R-CNN 等目标检测模型中的关键技术，依赖于卷积操作生成的特征图。

正则化 (Regularization) : 用于限制模型的复杂度，防止模型过拟合，使在训练集和验证集上表现更加一致，提高泛化能力。


权重衰减 (Weight Decay) : 使用 AdamW 优化器，其中包含权重衰减来防止模型过拟合。

ROIAlign [60] operation to extract the features of the certain individual from the MSAT knowledge-injected visual feature $\mathcal{V}^{SN}$ as follows:

$$\mathbf{P}_i = \text{ROIAlign}(\mathcal{V}^{SN}, b_i), \quad (7)$$

where $\mathbf{P}_i \in \mathbb{R}^r$ is the person feature in the bounding box b_i .

Implementation Details. We leverage AdamW [65] as the optimizer. We set the learning rate of all trainable parameters to 10^{-4} , weight decay to 0.05, training epoch to 6, batch size to 32. We utilize CosineAnnealing learning rate schedule to adjust the learning rate. We adopt the pre-trained CLIP ViT-B/16 [18] as vision encoder and the input images are resized to 224×224 . For MSAT, we set the transformer to 4 layers, the number of heads to 6. the dimension of transformer layers to



数据集介绍

PISC (People in Social Context) 包含社交场景中的人物图像，标注了3大类（亲密、非亲密、无关系）和6细类（朋友、家庭、夫妻、职业、商业、无关系）的社交关系。

PIPA (People in Photo Albums) 来自社交相册的3.7万张图像，将社会生活划分为5个广泛领域（家庭、朋友、 职业关系、商业关系、无关系）和16种更精细的社会关系（在粗粒度基础上进一步细分，例如：家庭 → 夫妻、亲子、兄弟姐妹；职业关系 → 同事、上下级）。

为什么需要分层级？

- 粗粒度（5类）适合快速筛选（标记“家庭照片”）。
- 细粒度（16类）挑战模型对微妙差异的捕捉（判断“这是亲子互动还是夫妻互动”）。

数据集	分类层级	数据来源	场景特点	人物关系	文中应用
PISC (People in Social Context)	三大类、六细类	从影视剧、公开视频中截取图像	动态交互场景（如对话、拥抱、握手）	聚焦人物间的显性互动（如肢体动作）	用于验证模型对即时交互的敏感性（如通过“亲吻”判断“夫妻”）。
PIPA (People in Photo Albums)	五大类、十六细类	从Flickr社交相册中收集的真实照片	静态生活场景（如聚会、旅行等）	更依赖于上下文线索（场景、物体）	测试模型对长期关系的推理能力（如通过“家庭合影”推断“亲子”）。



工作成果展示

Work achievement display

Places-365数据集 180万张场景图像，覆盖365类场景（如“厨房”“教堂”）。


在论文中，用于构建社会感知描述性提示（social prompts）中的场景类别和场景属性，例如通过场景词汇（如“教堂”）增强模型对“婚礼”场景的敏感度。


ImageNet-1k数据集 130万张图像，标注1,000类物体。

在论文中，用于提取物体类别词汇（如“玫瑰花”“戒指”），用于生成多模态提示，辅助模型关注社交关键物体。

COCO数据集 33万张图像，标注80类物体和实例分割。

在论文中，作为对比基线，指出其物体类别局限性（如缺少“婚戒”类别）促使作者采用CLIP的开放词汇能力。





下阶段执行计划

您的文字打在这里，您的文字打在这里，您的文字打在这
里,您的文字打在这里，您的文字打在这里



谢谢观看

T H A N K S

QUARTERLY SUMMARY