




# 论文汇报

## A Domain Based Approach to Social Relation Recognition

基于领域的社会关系识别法

汇报人: *yixuan*


时间: 2025.3.30



主要解决的问题

核心思想与贡献

其他收获



先前技术缺陷


技术实现细节



1

# 主要解决问题

第一部分



## ● 解决问题

---

● 如何将社会关系更系统地分类？

● 如何提高模型的泛化能力？

● 如何通过可解释性的视觉属性编码社会关系？

# ● 输入与输出

## → 输入

### 1. 原始图像

- 来源：Flickr公开照片（来自PIPA数据集扩展版）。
- 内容：包含至少两个可辨识人物的日常生活场景（如家庭聚会、职场活动）。

### 2. 预处理数据

- 人物检测：每个人物的头部和身体区域边界框（已标注）。
- 人物对生成：输入模型的实际数据是成对的图像（例如：人物A的头部 + 人物B的头部，或人物A的身体 + 人物B的身体）。



## 输出 →

### 1. 主要任务输出

- 社会关系分类：16种具体关系（如“父子”“同事”“朋友”）。
- 社会领域分类：5大领域（如“依恋”“等级权力”“联盟群体”）。

### 2. 辅助输出（可解释性）


- 关键语义属性：年龄差、服装类型、互动姿势等（见图6）。例如：“判定为父子，因检测到年龄差 + 拥抱动作”。
- 预测置信度：对模糊案例标注“maybe”（如两人可能是“朋友”或“同事”）。



2

# 先前技术缺陷

第二部分



# ● 先前缺陷与本文改进

## 以往缺陷:

局限于家庭亲属关系识别（夫妻、父母与孩子、兄弟姐妹、祖父母与孙子女），如：

- 夫妻关系通过面部位置和性别特征识别
- 亲子关系通过年龄差和面部相似性验证
- 兄弟姐妹关系通过年龄相近和性别特征判断

## 本文解决:

基于Bugental的领域理论，系统性地扩展为5大社会领域。

## 以往缺陷:

- 早期亲属识别研究如 [24]Wang et al.的 "Seeing people in social context" 仅使用数百张家庭照片
- Dehghan et al. 的亲属验证研究仅包含 1,000对亲子关系

## 本文解决:

本文构建的数据集包含26,915对人物关系标注，构建首个层次化标签空间（领域+关系）。



## 以往缺陷:

依赖临时规则（如“男性位置更高→丈夫”）或数据驱动特征（如面部相似性），未与社会心理学理论结合；提出“年龄相近+异性→配偶”的假设，未解释其社会意义，缺乏理论支撑。

## 本文解决:

将Bugental的社会领域理论作为计算机视觉分析社交关系的框架。该理论：

- 广泛覆盖我们的社交生活；
- 足够具体以便导出相关的社会关系；
- 能够支持计算建模和图像、视频中的识别。

## 以往缺陷:

依赖人工定义的特征（如面部相似性）或端到端黑箱模型，缺乏可解释性，且难以泛化。

## 本文解决:

设计语义属性模型，通过可解释的视觉属性（如年龄差、服装、互动姿势）编码社会关系，这些属性直接对应心理学理论中的社会线索。



# 3

## 核心思想与贡献

第三部分



## 核心思想

---

本文提出了一种**基于理论的社会关系识别方法**，旨在通过计算机视觉技术从静态图像中系统化地识别人物关系。


作者认为：

- 社会心理学中的领域理论为系统性地解决这一问题提供了良好的起点，因为该理论涵盖了社会关系的各个方面，并对定义每个领域中关系的视觉属性和行为具有具体和可预测性。
- 另外，要构建第一个基于这一整体概念化的社会生活的数据集，并提出识别这些领域和关系的模型，展示基于属性的特征在性能上的优势。
- 最后，可发现的可解释特征与社会心理学文献中的预测相一致，强调了视觉识别与社会心理学理论之间的紧密联系。

作者希望：

- 随着我们逐渐接近一个智能和潜在的自主系统成为我们的助手和同事的未来，希望它们不仅能熟练地完成任务，还能使它们能够在我们的生活的不同情境中融入并恰当地行动。
- 通过更好地理解这些隐含信息，希望能知晓用户潜在的隐私风险。

## ● 核心贡献



### 理论框架:

将Bugental的**社会领域理论**作为计算机视觉分析社交关系的框架。该理论：（1）可以广泛覆盖我们的社交生活；（2）足够具体以便导出相关的社会关系；（3）能够支持计算建模和图像、视频中的识别。

### 数据集:

通过对大规模Flickr照片数据集进行关系和领域标签的标注（新增了26915对人物关系标注，基于Bugental的五大领域），提供了一个比之前的工作更全面的数据集（PIPA扩展版）。

### 建模:

- 改进端到端训练的**CNN模型**，采用双流CaffeNet。
- 根据社会心理学研究收集人体和头部图像的**语义属性**，对属性的重要性进行深入分析，以弥合社会心理学理论与我们的计算模型之间的差距。



# 4

# 技术实现细节

第四部分

## 具体实现



- 一张包含至少两个人的图像（来自PIPA数据集）。
- 每个人物的头部和身体区域的边界框（已标注）。

### 模型架构:

- 两个独立的CaffeNet分支，分别处理两个人的图像区域。
- 每个分支包含5个卷积层（CONV1-CONV5）和全连接层（FC6-FC8）。

### 可选操作:

- 直接分类（端到端模型）：将两人特征拼接后输入FC8层，输出关系/领域概率分布。
- 属性提取（属性模型）：不使用FC8，进入下一步。（更优）

| 属性 | 计算方法                                                    |
|----|---------------------------------------------------------|
| 年龄 | 双流CNN提取两人头部特征 → 预训练年龄分类器 → 输出年龄标签（如child/adult）和年龄差。    |
| 性别 | 类似年龄，使用性别分类器判断male/female。                              |
| 服装 | 双流CNN提取身体区域特征 → 基于Berkeley数据集训练的服装分类器 → 输出（如tShirt/制服）。 |
| 互动 | 使用预训练的Multi-task RNN模型[10]分析两人姿势（如hug/highFive）。        |

### 使用线性SVM对综合属性向量进行分类

- 两级预测:
  1. 领域分类: 5类（如依恋、等级权力）。
  2. 关系分类: 16类（如父子、同事）。
- 决策依据:

属性权重与心理学理论一致（例如“年龄差大”对依恋领域贡献高，见图6）。

# 社会领域理论 (Bugental) :



Attachment (d0)



## 依恋领域：

**典型特征：**

在保护关系中维持亲密性

**典型关系：**

父子、母子、祖孙

**视觉线索：**

- 年龄差异大 (成人 vs. 儿童)
- 亲密互动 (如拥抱、牵手)
- 保护性姿势 (如成人站在儿童身后)



Reciprocity (d1)



## 互惠领域：

**典型特征：**平等互惠的关系，强调合作与长期利益交换

**典型关系：**朋友、兄弟姐妹、同学

**视觉线索：**

- 年龄相近
- 互动 (如聚会、分享)
- 积极效应的顺序交换 (如互动对称性、共同活动、表情同步)

## 交配领域：

**典型特征：**涉及选择和保护与性伴侣的接触

**典型关系：**恋人、配偶

**视觉线索：**

- 性别差异
- 亲密行为 (如接吻、搂肩)
- 外观吸引力 (如打扮精致)



Mating (d2)



lovers / spouses (r7)

## 等级权力领域：

**典型特征：**以使用或表达社会主导性为特征，主导性表现为资源提供和威胁行为。

**典型关系：**

演讲者和观众、师生、领导下属

**视觉线索：**

- 活动差异 (如倾听”和“赞同”这样的服从性活动对于缺乏主导性的人来说更加适应)



Hierarchical power (d3)



presenter – audience (r8)

teacher – student (r9)

trainer – trainee (r10)

leader – subordinate (r11)

## 联盟群体领域：

**典型特征：**涉及“我们”和“他们”之间的界限识别

**典型关系：**


乐队/舞蹈队/运动队成员、同事

**视觉线索：**

- 相似服装 (如制服、队服)
- 联合活动 (如演奏、比赛)



Coalitional groups (d4)



band members (r12)


dance team members (r13)

sport team members (r14)

colleagues (r15)

## 双流CaffeNet

从图像对到5个领域类别或  
16个关系类别的端到端映射



### 输入层

**输入：**人物A和B的头部/身体区域图像。

**操作：**将两人输入图像进行独立预处理，无数据混合。

**输出：**两个独立张量

### 双流卷积网络

**输入：**经预处理的图像

**操作：**两分支（人物A流和人物B流）各包含5个CONV层，独立提取人物特征，避免特征混淆。

**输出：**包含特征的多维张量

### 特征融合

**输入：**双流CONV5输出

**操作：**先经过FC6初级融合层，拼接双流特征，保留基础交互信息（如空间相对位置）；再经过FC7高阶抽象层，提炼社会关系的关键行为模式（如表情同步）。

**输出：**高阶交互特征

### 输出层

**输入：**FC7的输出

**输出：**类别概率分布，映射到Bugental定义的关系/领域标签。



语义属性模型

AC: 测试模型能否正确识别所有16种社会关系和5大领域。

SR: 测试模型能否正确理解社会领域的本质。即若没见过某具体社会关系，是否能识别出它属于5大领域中的哪个。


|         |                      | 常规测试（AC splits） |        | 泛化测试（SR splits） |
|---------|----------------------|-----------------|--------|-----------------|
| MODEL   |                      | RELATION        | DOMAIN | GENERALIZATION  |
| 端对端模型   | END-TO-END SCRATCH   | 34.4%           | 41.9%  | —               |
|         | END-TO-END FINETUNED | 46.2%           | 59.0%  | 18.5%           |
| 预训练+SVM | PRE-TRAINED, SVM     | 35.9%           | 53.3%  | 27.7%           |
| 微调+SVM  | FINETUNED, SVM       | 48.6%           | 63.2%  | 27.1%           |
| 属性模型    | HEAD ATTRIBUTES, SVM | 44.8%           | 59.4%  | 21.5%           |
|         | BODY ATTRIBUTES, SVM | 57.2%           | 67.7%  | 32.8%           |
|         | ALL ATTRIBUTES, SVM  | 57.2%           | 67.8%  | 33.3%           |

表7：关系○领域识别的准确率（[113]）和领域泛化（[108]）

属性模型分出三个变体：HEAD ATTRIBUTES, SVM（仅使用头部相关属性，如年龄、性别、表情、发型等）、BODY ATTRIBUTES, SVM（仅使用身体相关属性，如服装、姿势、互动动作等）、ALL ATTRIBUTES, SVM（融合头部+身体所有属性，**最优结果**）

验证：

- 1. 身体属性比头部属性更重要 与图6结论一致（活动/服装是Top贡献属性）。
- 2. 融合头部+身体所有属性效果最佳 "BODY"和"ALL"在关系识别上数值相同（57.2%），领域分类和泛化能力略优，说明头部属性起到补充作用。



图●：每个单一属性类别在关系与领域模型中相对识别贡献

## 结构

**x轴：**单属性对领域分类的贡献（归一化）

**y轴：**单属性对关系识别的贡献（归一化）

**点：**每个点代表一个属性类别，共12个类别，分别是互动活动、服装、身体性别、头部年龄、相对位置、头部性别、面部表情、头部姿势、发型与配饰、身体年龄、头部位置与大小、身体位置与大小。

## 可视化分析

**大多数属性位于对角线以下：**大多数属性对领域分类的贡献高于关系识别，因为关系识别涉及更多类和更精细的粒度。

**高贡献属性（右上角）：**activity&clothing

- 活动直接反映互动模式（如“拥抱”→亲子，“握手”→同事）。
- 服装体现社会角色（如“制服”→同事，“礼服”→配偶）。

例如：乐队成员（Coalitional Groups）通过“相同服装+共同演奏”被识别。

**较高贡献属性（中下部）：**body gender&head age

这是因为在社会心理学对交配领域和依恋领域的定义中，年龄和年龄差异、性别和性别差异是主导特征，年龄差和性别组合可区分领域。

例如：“大年龄差+异性”→依恋领域、“同龄+同性”→朋友

**低贡献属性（左下部）：**如proximity、face emotion、head pose

这是因为姿势、情绪等在静态图像中噪声大，不易准确识别。

例如：“微笑”可能出现在各种关系中





图X: 属性模型在实际预测中的表现, 包括正例☺☺ (正确预测) 与负例☹☹ (错误预测)




图7: 每个单一属性类别在关系与领域模型中相对识别贡献

### 图7的结构与内容

展示多组人物对的图像, 每组包含:

- 真实关系标签 (Ground Truth)
- 全属性模型的预测结果
- Top 4单属性模型的预测结果 (对应图6中贡献最高的4类属性)
- 正例: 全属性模型预测与真实标签一致。
- 负例: 全属性模型预测错误, 但部分单属性模型可能正确 (揭示错误原因)。

### 典型正例分析

- (d)模糊背景下的同事: 互动 (面对面交谈)+服装相似 (同色系西装)→同事  
(e)祖母-孙子: 互动 (拥抱)+服装 (日常便装)+性别差 (性别相反)+年龄差 (老人与儿童)→祖母-孙子

### 典型负例分析

- (i)异常互动的祖孙: 互动 (“朋友”玩耍) ×+性别差 (性别相反) ✓+年龄差 (老人与儿童) ✓→朋友 (错因: 互动属性过拟合)

- (l)缺乏线索的同事: 互动 (无同事相关工作)+服装 (疑似工作制服但不清晰)→朋友

### 图7与图6的核心关联

1. 验证属性贡献度: 图7的成功案例依赖图6中的高贡献属性 (如Activity、Clothing); 图7的失败案例反映图6属性的局限性 (如单一高贡献属性可能过拟合)。
2. 可解释性体现: 图7展示的错误可通过调整属性权重 (参考图6) 优化, 而端到端模型无法提供此类修正路径。

# 5

## 第五部分

# 其他收获

- 深度学习应用
- 数据集介绍
- 评价指标

# 深度学习应用

---

**1.卷积 (Convolution) :** 卷积操作是卷积神经网络的核心，用于提取图像的局部特征。

在**训练双流CNN**时，每个分支中都使用5个卷积层 (CONV1-CONV5) 提取视觉特征。

**2.池化 (Pooling) :** 降低数据的维度 (降采样)，减少计算量，同时还能提取主要的特征，防止过拟合。池化操作通常跟在卷积层之后，对卷积输出的特征图进行处理。

在**训练双流CNN**时，每个卷积层后接池化层 (如CONV1→POOL1)，用于降维和特征压缩。

**3. 数据增强 (Data Augmentation) :** 增加数据多样性，防止过拟合 (尤其对PIPA数据集中的人物姿态变化敏感的场景)。

在**训练双流CNN**时，对输入图像进行增强，具体有：随机裁剪、水平翻转、亮度/对比度调整等。

**4. Softmax函数:** 将神经网络输出转化为概率分布，便于分类决策。

在**端到端模型**中，在fc8层后接Softmax，输出16种关系或5大领域的概率。



# 深度学习应用

---

**5. 正则化 (Regularization)** : 用于限制模型的复杂度, 防止模型过拟合, 使在训练集和验证集上表现更加一致, 提高泛化能力。

训练**双流CNN**时,

- Dropout: 在fc6和fc7层使用 (丢弃率通常为0.5) 。
- L2权重衰减: 约束卷积核和全连接层权重, 防止过拟合。

**6. 归一化 (Normalization)** : 提升模型稳定性和性能的关键技术。

- 数据归一化 (输入预处理)

在输入**双流CNN**前, 对像素值进行归一化。将像素值从  $[0, 255]$  线性缩放至  $[0, 1]$  或标准化为均值为0、方差1的分布。避免数值量纲差异导致的优化困难 (如服装颜色和面部亮度的数值范围不同) 。

- 特征归一化 (语义属性处理)

在**属性模型**中, 对不同来源的语义属性特征 (如年龄、服装、活动) 进行归一化。



# 数据集介绍

## PIPA (People in Photo Albums)

**原始数据集标注：**PIPA包含37,107张照片，具有63,188个实例和2,356个身份。对于每个标注的人，已经提供了**头部边界框、身份ID、性别、年龄的标注**。同一个人经常出现在不同的社交场景中，并与不同的人互动。

### 本文新增标注：

- **5大领域、16类关系**（如，标注：依恋关系，母亲-孩子）；
- **一致性水平**（如，标注：consistency=3 表示 agr  $\geq 3$  至少有三位注释者对一对人员给出了完全相同的标签）；
- **头/身体属性类别**（如，标注：
  - ◆ infant/child/young/middleAge/senior/unknown表示**年龄属性**；
  - ◆ 小年龄差异/中年差异/大年龄差异表示**年龄差异**；
  - ◆ 同性/异性表示**性别差异**；
  - ◆ 位置、规模、相对距离；头部外观；头部姿势，面部表情；服装；接近性动作如从后面抱/握手/击掌/拥抱/手臂搭肩/肩并肩和手臂插在一起；活动如调整、降落、鼓掌、整理、攻击等）。



## 数据集介绍

| 其他数据集     | 数据量                      | 在本文中作用                                         |
|-----------|--------------------------|------------------------------------------------|
| CelebA    | 包含10,177个身份的202,599张头部照片 | 标注40个类别的头部外观，例如直发、波浪发、佩戴耳环、佩戴帽子等。              |
| IMFDB     | 包含34,512张从电影中收集的头部图像     | 标注姿势包括正面、左侧、右侧、向上和向下。情感包括愤怒、快乐、悲伤、惊讶、恐惧、厌恶和中性。 |
| Berkeley  | 包括 8035 张身体图像            | 标注服装，如长发、眼镜、帽子、T恤、短裤、牛仔裤、长裤和长袖子。               |
| Activity  | 126,102张图像               | 标注人类活动，包括调整、降落、鼓掌、整理、攻击、膨胀、施洗等。                |
| Proximity | 10k 图像                   | 标注接近性动作，包括从后面抱，握手，击掌，拥抱，手臂搭肩，肩并肩和手臂插在一起。       |

# 评价指标

| MODEL                | RELATION | DOMAIN | GENERALIZATION |
|----------------------|----------|--------|----------------|
| END-TO-END SCRATCH   | 34.4%    | 41.9%  | —              |
| END-TO-END FINETUNED | 46.2%    | 59.0%  | 18.5%          |
| PRE-TRAINED, SVM     | 35.9%    | 53.3%  | 27.7%          |
| FINETUNED, SVM       | 48.6%    | 63.2%  | 27.1%          |
| HEAD ATTRIBUTES, SVM | 44.8%    | 59.4%  | 21.5%          |
| BODY ATTRIBUTES, SVM | 57.2%    | 67.7%  | 32.8%          |
| ALL ATTRIBUTES, SVM  | 57.2%    | 67.8%  | 33.3%          |

## 一、分类准确率（accuracy）

公式：Accuracy =  $\frac{\text{正确预测的样本数}}{\text{总样本数}} \times 100\%$


- 表1中，“relation”和“domain”分别对应表示社会关系识别和社会领域分类的**准确率**。
- 其中，融合头部+身体属性模型在关系识别上达到57.2%，领域分类达到67.8%，表明此模型效果最佳。

## 二、留一关系准确率（single-relation accuracy）

- 在留一关系实验中，模型对未见过的关系的领域分类准确率，即测试模型的泛化能力。表1中，“generalization”列表示**留一关系准确率**。
- 其中，融合头部+身体属性模型的泛化准确率33.3%，显著高于其他模型。



# 评价指标



图●：每个单一属性类别在关系与领域模型中相对识别贡献

## 三、归一化贡献值

$$\text{公式：贡献值} = \frac{\text{单属性模型准确率}}{\text{全属性模型准确率}}$$

- 本文量化了不同语义属性对分类任务的贡献，验证了心理学理论的可计算性，并揭示了模型决策的内在逻辑。
- 图6中，横纵轴分别表示单属性对领域分类和关系识别的归一化贡献值。例如：活动与服装两者在领域和关系识别中贡献均最高（图6右上角），符合理论中“行为与外观是社会关系核心线索”的预测。



# 评价指标

TABLE V

EFFICIENCY ANALYSIS OF CONSoR VARIANTS. ALL EXPERIMENTS WERE CONDUCTED USING TWO NVIDIA GeForce RTX 3090 Ti GPUs WITH 16 BATCH-SIZE. CONSoR STRIKES A GOOD BALANCE BETWEEN PERFORMANCE AND COMPLEXITY/EFFICIENCY

| Methods       | Train.Params.(M) | TotalParams.(M) | GPUMem.(MB/GPU) |
|---------------|------------------|-----------------|-----------------|
| CLIP-ZeroShot | 0                | 149             | 1,628           |
| CLIP-Frozen   | 7.6              | 157             | 2,256           |
| CLIP-Finetune | 157              | 157             | 5,706           |
| ConSoR-Visual | 19.4             | 105             | 2,760           |
| ConSoR-ObjDet | 20               | 214             | 4,535           |
| <b>ConSoR</b> | <b>20</b>        | <b>170</b>      | <b>3,554</b>    |

TABLE IV

COMPARISON WITH CONSoR VARIANTS. WE PERFORMED ABLATIONS FIVE TIMES AND CONDUCTED T-TESTS BETWEEN EACH ABLATION AND CONSoR. THE RESULTS INDICATE THAT CONSoR IS STATISTICALLY SIGNIFICANTLY SUPERIOR IN MOST CASES.

| Methods       | PISC (mAP)       |                   |                  |                  |         | PIPA (Acc@1)     |                  |                   |                  |         |
|---------------|------------------|-------------------|------------------|------------------|---------|------------------|------------------|-------------------|------------------|---------|
|               | Coarse           |                   | Fine             |                  | p-value | Coarse           |                  | Fine              |                  | p-value |
|               | mean ± std.      | p-value           | mean ± std.      | p-value          |         | mean ± std.      | p-value          | mean ± std.       | p-value          |         |
| CLIP-ZeroShot | 36.20±.00        | 10 <sup>-11</sup> | 30.40±.00        | 10 <sup>-9</sup> |         | 34.80±.00        | 10 <sup>-9</sup> | 39.00±.00         | 10 <sup>-7</sup> |         |
| CLIP-Frozen   | 86.60±.21        | 10 <sup>-9</sup>  | 77.72±.61        | 10 <sup>-8</sup> |         | 78.72±.54        | 10 <sup>-5</sup> | 73.36±.43         | 0.003            |         |
| CLIP-Finetune | 88.22±.26        | 10 <sup>-6</sup>  | 82.08±.40        | 10 <sup>-6</sup> |         | 77.82±.67        | 10 <sup>-6</sup> | 73.00±.37         | 0.002            |         |
| ConSoR-Visual | 90.34±.30        | 0.109             | 84.62±.45        | 0.094            |         | 82.38±.54        | 0.877            | 75.84±.36         | 0.389            |         |
| ConSoR-ObjDet | 89.94±.25        | 0.513             | 84.76±.66        | 0.274            |         | 81.28±.57        | 0.017            | 76.24±1.21        | 0.860            |         |
| <b>ConSoR</b> | <b>90.24±.21</b> | -                 | <b>85.80±.51</b> | -                |         | <b>82.44±.64</b> | -                | <b>76.38±1.22</b> | -                |         |

TABLE VI

ABLATIONS ON MSAT MODULES. THE INCORPORATION OF MSAT EFFECTIVELY MITIGATES SEVERE OVERFITTING ISSUES AND ENHANCES EFFICIENCY.

| Methods                | PISC (mAP)       |                  | PIPA (Acc@1)     |                   | Trainable Params.<br>(Million) | GPU Memory<br>(MB/GPU) |
|------------------------|------------------|------------------|------------------|-------------------|--------------------------------|------------------------|
|                        | Coarse           | Fine             | Coarse           | Fine              |                                |                        |
| ConSoR-Visual w/o MSAT | 89.36±.37        | 83.58±.42        | 78.10±.33        | 72.98±.70         | 102                            | 5,898                  |
| <b>ConSoR-V</b>        | <b>90.34±.30</b> | <b>84.62±.45</b> | <b>82.38±.54</b> | <b>75.84±.36</b>  | <b>19.4</b>                    | <b>2,760</b>           |
| ConSoR w/o MSAT        | 66.94±2.72       | 57.32±3.53       | 66.46±1.66       | 60.88±2.97        | 166                            | 9,596                  |
| <b>ConSoR</b>          | <b>90.24±.21</b> | <b>85.80±.51</b> | <b>82.44±.64</b> | <b>76.38±1.22</b> | <b>20</b>                      | <b>3,554</b>           |

TABLE III

EXPERIMENTAL RESULTS ON PISC AND PIPA DATASET. WE OUTPERFORM SOTA METHODS BY ACHIEVING +12.2 mAP IMPROVEMENT ON THE PISC-FINE DATASET, WHICH IS CONSIDERED THE PRIMARY METRIC FOR EVALUATING VISUAL SOCIAL RELATION RECOGNITION TASK. (INT.: INTIMATE, NON.: NON-INTIMATE, NoR.: NO RELATION, Fri.: FRIEND, Fam.: FAMILY, Cou.: COUPLE, Pro.: PROFESSIONAL, Com.: COMMERCIAL.) THE PIPA-COARSE/PIPA-FINE DATASET IS 5/16-CLASS CLASSIFICATION, RESPECTIVELY.

| Methods                | PISC Coarse |      |      |                    | PISC Fine |      |       |      |      |      | PIPA Coarse         |                    | PIPA Fine          |
|------------------------|-------------|------|------|--------------------|-----------|------|-------|------|------|------|---------------------|--------------------|--------------------|
|                        | Int.        | Non. | NoR. | mAP                | Fri.      | Fam. | Cou.  | Pro. | Com. | NoR. | mAP                 | Acc@1              | Acc@1              |
| Pair-Box-CNN [13]      | 70.3        | 80.5 | 38.8 | 65.1               | 30.2      | 59.1 | 69.4  | 57.5 | 41.9 | 34.2 | 48.2                | 65.9               | 58.0               |
| Dual-Glance [13]       | 73.1        | 84.2 | 59.6 | 79.7               | 35.4      | 68.1 | 76.3  | 70.3 | 57.6 | 60.9 | 63.2                | -                  | 59.6               |
| GRM [14]               | 81.7        | 73.4 | 65.5 | 82.8               | 59.6      | 64.4 | 58.6  | 76.6 | 39.5 | 67.7 | 68.7                | -                  | 62.3               |
| MGR [34]               | -           | -    | -    | -                  | 64.6      | 67.8 | 60.5  | 76.8 | 34.7 | 70.4 | 70.0                | -                  | 64.4               |
| SRG-GN [37]            | -           | -    | -    | -                  | 25.2      | 80.0 | 100.0 | 78.4 | 83.3 | 62.5 | 71.6                | -                  | 53.6               |
| GR <sup>2</sup> N [15] | 81.6        | 74.3 | 70.8 | 83.1               | 60.8      | 65.9 | 84.8  | 73.0 | 51.7 | 70.4 | 72.7                | 72.3               | 64.3               |
| HF-SRGR [36]           | 89.1        | 87.0 | 75.5 | 84.6               | 82.2      | 39.4 | 33.2  | 60.0 | 47.7 | 71.8 | 73.3                | -                  | 65.9               |
| GA-GCN [40]            | 87.3        | 86.0 | 89.8 | 87.7               | 63.1      | 73.5 | 78.3  | 82.7 | 76.8 | 71.8 | 73.6                | -                  | 66.6               |
| SRR-LGR [41]           | 89.6        | 84.6 | 78.5 | 84.8               | 83.9      | 52.4 | 35.9  | 64.0 | 54.0 | 63.6 | 73.0                | -                  | 66.1               |
| PRM [39]               | -           | -    | -    | -                  | 56.5      | 70.8 | 72.3  | 78.5 | 81.4 | 68.3 | 73.2                | 73.2               | 65.6               |
| <b>ConSoR (Ours)</b>   | 91.3        | 78.7 | 71.0 | <b>90.2 (+2.5)</b> | 80.9      | 80.2 | 75.8  | 90.4 | 45.2 | 76.1 | <b>85.8 (+12.2)</b> | <b>82.4 (+9.2)</b> | <b>76.4 (+9.8)</b> |

TABLE VIII

ABLATION STUDY OF DIFFERENT FUSION STRATEGIES FOR MSAT ON PISC-FINE DATASET. EACH FUSION LAYER CONTAINS THE TEXT AND VISUAL FEATURES SPECIFIC TO ITS CORRESPONDING LAYER.

| Strategies          | Fusion Layers       | mAP         |
|---------------------|---------------------|-------------|
| w/o fusion          | -                   | 79.8        |
| Single-layer Fusion | 0th layer           | 80.2        |
|                     | 3rd layer           | 81.7        |
|                     | 6th layer           | 82.6        |
|                     | 9th layer           | 83.5        |
|                     | 12th layer          | 84.1        |
| Multi-layers Fusion | (9,12)-layers       | 85.1        |
|                     | (6,9,12)-layers     | 85.5        |
|                     | (3,6,9,12)-layers   | 85.6        |
|                     | (0,3,6,9,12)-layers | <b>85.8</b> |

# 评价指标

---

## 一、mAP (mean Average Precision, 平均精度均值)

- 用于多类别分类或检测任务的综合性能评估，计算所有类别的平均精度 (AP) 的均值。
- mAP是本文在PISC-Fine数据集上的核心评价指标，用于衡量多类别社交关系识别的综合性能。体现ConSoR优势：捕捉隐含社交线索，开放词汇能力。

## 二、Accuracy (整体准确率)

- 模型预测正确的样本数占总样本数的比例。
- 文中Accuracy用于评估PIPA数据集（16类社交关系）的分类效果。体现ConSoR优势：细粒度关系分类，建模社交属性（如传递性）。

## 三、Trainable Params. (Million)

- 模型在训练过程中需要更新的参数总数，反映模型复杂度和计算资源需求。
- 体现ConSoR优势：轻量化适配器，避免过拟合。

## 四、GPU Memory (MB/GPU)

- 模型训练时占用的 GPU 内存（显存），直接影响硬件需求和训练 / 推理速度，反映了模型的资源消耗。
- 体现ConSoR优势：低显存占用，显著提高了模型的效率。



THANKS

演示完毕  
感谢观看