



学习成果汇报



学生: yíxuan



日期: 2025.4.15

目录

01 论文分析

02 其他

论文题目: Social Relation Recognition from Videos via Multi-scale Spatial-Temporal Reasoning

通过多尺度时空推理从视频中识别社会关系

论文分析目录

01

主要解决问题

02

现有技术不足

03

核心思想与贡献

04

技术实现细节

05

其他收获

01

主要解决问题

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec luctus nibh sit amet sem vulputate venenatis bibendum orci pulvinar.

主要解决的问题

问题一

如何更好地基于**视频**做社会关系识别？

01

问题二

如何更好地在**空间和时间两个维度**进行人物关系推理？

02

输入输出


输入

输入视频片段，通过采样得到多帧图像，每帧中包含检测到的人物和物体的边界框。



输出

输出视频的社交关系类别（如父母—子女、夫妻、同事等）。



Sampled Frames



.....



Colleague

02 现有技术缺陷

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec luctus nibh sit amet sem vulputate venenatis bibendum orci pulvinar.

现有技术缺陷

➤ 基于视频的社会关系识别技术缺陷

- 现有方法主要集中在静态图像上：由于个人和物体可能出现在任意帧中，图像方法失效；
- 现有视频方法过于简化，仅被视为普通视频分类任务：如TSN-ST仅用RGB和光流特征，难以区分视觉相似关系；又如GCN采用固定的感受野，无法同时捕捉短时动作和长期模式。

➤ 细粒度人物-物体关系的缺乏

- 忽略物体上下文：传统GCN和图像方法（如GRM）仅建模人物间关系，忽视物体对社会关系的判别作用，导致丢失关键语义线索。
- 单一邻接矩阵：传统GCN使用单一的邻接矩阵 A 描述所有节点间的关系，无法区分不同类型的关系（如人物 - 人物、人物 - 物体）。若图中包含多种关系，传统GCN会将其混合处理，导致信息模糊。

➤ 现有数据集规模小、标注质量低

现有的社交关系识别数据集主要基于静态图像，而带有明确社会关系标签的视频数据集非常稀缺。其中最大的视频中的社会关系 (SRIV) 数据集，限制：

- 1) 数据集的体量相对较小，难以支持模型的可扩展性，特别是对于 CNN；
- 2) 视频由多个标签标记，这使得视频中的关系模糊；
- 3) 社会关系非常不平衡，尤其是对于客观关系。

03

核心思想与贡献

Research Results And Its Application

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec luctus nibh sit amet sem vulputate venenatis bibendum orci pulvinar.

核心思想

提出**多尺度时空推理** (MSTR) 框架, “多尺度”主要体现在空间和**时间**两个维度。

- 空间多尺度MSR = 全局 (TSN) + 局部 (Triple Graphs), 既考虑整体场景, 又分析人物和物体的细节交互。
- **全局尺度**使用 TSN提取整个视频帧的场景和背景特征。
- **局部尺度**采用 Triple Graphs (三重图) 建模细粒度的人物和物体关系。
- 空间多尺度MTR, 提出金字塔图卷积网络 (PGCN)。
- **长期时间尺度**, 使用全时序邻接矩阵, 覆盖整个视频的所有帧, 捕捉长期行为模式。
- **短期时间尺度**, 使用滑动窗口分析局部时间段, 检测关键瞬时交互。
- 多尺度融合, 同时建模长短期动态, 避免仅依赖单一时间范围导致的偏差。




核心贡献

- 提出多尺度时空推理 (MSTR) 框架, 通过在时空领域中使用全局—局部、长期—短期信息从视频中识别社会关系。
- 设计三重图模型, 表示视觉关系中的人物与物体。并与TSN结合, 从视频帧中学习多尺度空间特征。
- 提出PGCN, 有效捕捉视频中的长期和短期时间线索, 它通过多尺度时间感受野进行关系推理。
- 构建大规模视频社交关系数据集ViSR, 它不仅包含超过 8,000 个标记有八种日常生活常见社交关系的视频片段, 还具有多样的场景、环境和背景。


04 技术实现细节

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec luctus nibh sit amet sem vulputate venenatis bibendum orci pulvinar.

选题的背景与意义



三重图 (Triple Graphs)



IntraG: 同一人在视频中的变化

邻接矩阵 A_s 的取值规则:

- 行和列的索引对应于视频中边界框的时间顺序, 从而使时间信息隐式嵌入到构建的图中;
- 如果人物实例 p_i (第 i 帧) 和 p_j (第 j 帧) 视觉相似度高, 则表示是同一人, 即 $A_s(p_i, p_j) = 1$, 否则为0。

示例:

- 若"男人"在帧1和帧5的外观相似, 则 $A_s(1, 5) = 1$ 。
- 若帧10中"男人"背对镜头导致相似度低, 则 $A_s(1, 10) = 0$ 。

InterG: 不同人物间的交互行为

邻接矩阵 A_d 的取值规则:

- 同一帧内: 若两人出现在同一帧, 则 $A_d(p_i, p_j) = 1$;
- 相邻帧内: 若两人在相邻帧视觉差异大 (即可能发生互动), 则 $A_d(p_i, p_j) = 1$, 否则为0。

示例:

- 帧3中"男人"和"孩子"同框, $A_d(3男, 3子) = 1$ 。
- 帧5的"男人"与帧6的"孩子"姿势差异大, $A_d(5男, 6子) = 1$ 。

POG: 人物与场景物体的共存关系

邻接矩阵 A_o 的取值规则:

- 人物 p_k 和物体 o_l 在同一帧出现时, $A_o(p_i, p_j) = 1$, 否则为0。

示例:

- 帧2中"男人"和"蛋糕"同框 $\rightarrow A_o(2男, 2蛋糕) = 1$;
- 帧7中"孩子"和"玩具"同框 $\rightarrow A_o(7子, 7玩具) = 1$ 。

金字塔图卷积网络 (PGCN)

图卷积网络 (GCN)

GCN的传播公式:

$$X^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X^{(l)} W^{(l)}),$$

1.输入:

- 当前层特征 $X^{(l)}$ (N 个节点, 每个节点 d 维特征)。

- 归一化邻接矩阵 $A = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$

2.矩阵乘法:

$$\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X^{(l)}$$

- 聚合邻居特征。

- 例如: 若"父亲"在帧1和帧5相连, 则帧1的特征会吸收帧5的信息。

3.权重变换:

$$\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X^{(l)} W^{(l)}$$

乘可学习参数 W , 映射到新的特征空间。

4. 非线性激活:

$$X^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X^{(l)} W^{(l)}),$$

通过 σ (如ReLU) 引入非线性, 得到更新后的特征 $X^{(l+1)}$ 。

5.输出: 节点的新特征, 包含自身及其关联节点的信息。




Figure 3. Pyramid Graph Convolution Block with multi-scale receptive fields in the temporal domain. Here we use A to represent the normalized adjacent matrix $\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$ for simplicity.

注:

● 初始特征矩阵 $X(0)$ 的生成方法:

- 一段视频, 按固定间隔 (如每秒1帧) 采样为 F 帧 (如20帧)。
- 使用预训练的目标检测模型 (如 Mask R-CNN) 对每帧进行检测, 得到: 人物边界框、物体边界框, 每个检测到的人物或物体被视为图中的一个节点。
- 对每个节点的边界框, 使用预训练的CNN模型 (如 ResNet-50) 提取视觉特征。

● GCN逐层更新特征的原因:

第1层 $x(1)$: 聚合直接邻居的特征。

第2层 $x(2)$: 聚合邻居的邻居的特征。

...

金字塔图卷积网络 (PGCN)




Figure 3. Pyramid Graph Convolution Block with multi-scale receptive fields in the temporal domain. Here we use A to represent the normalized adjacent matrix $\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$ for simplicity.

GCN—>PGCN改进增强

- 多尺度时序建模：引入金字塔卷积，捕捉**长短时序**依赖。
- 三重图结构：分别建模人物内、人物间、人物-物体关系，提升社交关系识别的准确性。（三个邻接矩阵 A_s 、 A_d 、 A_o ）

金字塔图卷积网络 (PGCN)

通过**多尺度时间窗口**对视频中的社交关系进行分层推理，核心在于**同时捕捉长期行为模式和短期关键动作**。

Scale 1 (全局尺度)

- 目标：建模视频的**完整时间范围**，捕捉人物或物体的**长期依赖关系**。
- 输入：对整个邻接矩阵执行标准图卷积。
- 特点：感受野覆盖所有帧，适合分析"全程同框" "整体场景"等全局特征（如：两人80%时间同框 → 可能为"家人"；全程无互动 → 可能为"陌生人"。）。
- 局限性：可能忽略短暂但关键的互动（如瞬间握手）。

金字塔图卷积网络 (PGCN)




Figure 3. Pyramid Graph Convolution Block with multi-scale receptive fields in the temporal domain. Here we use A to represent the normalized adjacent matrix $\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$ for simplicity.

Scale 2 (局部尺度)

- 目标：聚焦**短期时间窗口**，捕捉瞬时的交互或动作。
- 实现方式：
 - 输入：将邻接矩阵 A 划分为多个子矩阵（如每5帧一个窗口，步长2帧）。
 - 对每个子矩阵执行图卷积。
 - 滑动窗口**沿对角线移动**（确保时间连续性）。
- 特点：感受野短，适合检测“握手”“递物品”等短暂动作（如：帧3-7中“两人握手”→强化“同事”证据；帧11-15“拥抱”→强化“家人”证据。）。
- 优势：避免全局卷积对局部信号的忽视。

Scale k (一般尺度)

- 目标：通过灵活调整窗口大小，适应不同长度的动作模式。
- 实现方式：根据任务需求设置多个尺度（如Scale 3窗口 = 10帧，Scale 4窗口 = 15帧）。

05 其他收获

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec luctus nibh sit amet sem vulputate venenatis bibendum orci pulvinar.

名词解释

节点 (Node) 在图结构中，节点 (Node) 表示实体或对象。具体到PGCN中的视频分析中，每个节点代表视频中某一时刻的一个人或物体，是图的基本构建单元。如第1帧的"父亲"、第3帧的"蛋糕"。


特征向量 (Feature Vector) 特征向量是一个数值向量，用于描述节点的属性或状态。在PGCN中：

- 特征向量的**来源**：通过预训练模型（如ResNet）提取视觉特征。
- 特征向量的**维度d**：
 - 指描述一个节点所用的数值特征的维度数量。
 - 在PGCN中，d 通常是几百到几千维（如d=2048 来自ResNet的最后一层，d=2048 的向量可以同时编码人物的姿势、服装、表情、物体类别等多种信息）。
 - 高维空间更容易区分视觉上相似但语义不同的对象，如："穿红衣服的父亲"和"穿红衣服的陌生人"可能在低维空间接近，但在高维空间可通过其他特征（如面部特征）分离。

混淆矩阵 (Confusion Matrix)

评估分类模型性能的N×N表格（N 为类别数），用于直观展示模型预测结果与真实标签的对应关系。

如图，对角线数据表示正确预测的样本数；非对角线数据代表误判样本数。



ViSR 数据集

Table 1. The descriptions of social relations in the ViSR dataset based on the domain theory [3].

Domain	Relation	Examples
Attachment	Parent-offspring	Parent-child, Grandparent-grandchild
Mating	Couple	Husband-wife, boyfriend-girlfriend
Hierarchical power	Leader-subordinate Service	Teacher-student, team leader-member Passenger-driver, Customer-waiter
Reciprocity	Sibling Friend	Brothers, sisters Friends in general scenes
Coalitional groups	Colleague Opponent	Co-worker, school mate, teammate Enemy, competitor, disputant

ViSR数据集，定义来自基于领域理论的八种社会关系类型。

● 构建过程：

- 首先收集了200多部多种类型的电影，并排除超现实类型。
- 邀请十位注释者从电影中分割视频片段。每个片段的长度限制在10~30秒之间。片段中必须存在至少两个人进行互动。一个片段中的场景应该是固定的，以此获得约10,000个候选视频片段以供注释。
- 每个候选视频片段至少由五位注释者通过最大投票标记，以确保质量。如果所有标签的投票数少于三票，则该片段将被丢弃。

● 特性：

- 体量相对较大：包含超过8000个有效的视频片段。
- 类别适宜：不仅覆盖了日常生活中大多数常见的社交关系，且其类别分布均衡。
- 场景稳定：大多数片段的长度限制在30秒以内，以保持稳定的场景，从而减少视频中关系的模糊性。





Figure 4. The statistics of video clip length in ViSR dataset.



评价指标

一、mAP (mean Average Precision, 平均精度均值)

- 用于多类别分类或检测任务的综合性能评估, 计算所有类别的平均精度 (AP) 的均值。

二、Top-1 Accuracy (Top-1准确率)

- 计算模型预测正确 (即预测的类别与样本的真实类别相同) 的样本数量占总测试样本数量的比例。

三、混淆矩阵的衍生指标

- 准确率 (Accuracy): $\text{对角线和} / \text{总样本数} = (50 + 45 + 40) / 158 \approx 85.4\%$ 。
- 精确率 (Precision): 以"朋友"为例, $45 / (45 + 5 + 4) = 83.3\%$ 。
- 召回率 (Recall): 以"家人"为例, $50 / (50 + 5 + 3) = 86.2\%$ 。


假设数据有3类: 家人 (F)、朋友 (R)、同事 (C) :

	预测:F	预测:R	预测:C
真实:F	50	5	3
真实:R	2	45	8
真实:C	1	4	40



请识别图中人物关系

仅从图片看，她们可能是同学关系，在实验室共同进行实验操作；也可能是师生关系，一方指导另一方实验；或是科研团队里的同事，协作开展科研项目。缺乏更多信息，难以确切判定。



请识别图中人物关系

仅根据图片难以精准判定人物关系，可能是同事关系，在工作场景中交流设备相关事宜；也可能是师徒关系，一方在指导另一方熟悉设备操作或检查要点等；或者是上级与下级关系，进行工作视察与沟通。缺乏更多信息的情况下，无法确切知晓。



请识别图中人物关系

图中两人可能是情侣、夫妻或者关系亲密的朋友。他们穿着实验室或医疗场所的防护服，戴着蓝色的帽子，彼此亲密地相拥，面带微笑，显示出两人之间亲密友好的关系。这种着装和场景通常出现在需要无菌操作的环境中，比如实验室、手术室等。




请识别图中人物关系

图中靠得很近、面带微笑的一男一女可能是夫妻或者亲密的伴侣关系。他们之间亲昵的姿态和温馨的互动显示出彼此关系的亲密。背景是一个图书馆，有书架和书籍，后方还有一位女士，可能是图书馆工作人员或是只是同处一个空间的其他人。



请识别图中人物关系

图中人物是同学关系，他们处于教室环境，在课桌前就座，共同参与学习活动。



请识别图中人物关系

🔗 分享 ...

图中应该是一家三口。画面中间的女士被右侧穿着白色上衣的男士搂着，两人可能是夫妻关系；左侧穿着蓝色上衣的小男孩依偎在女士身旁，可能是这对夫妻的孩子。他们看起来像是在餐厅一起用餐，氛围温馨。



请识别图中人物关系

图中两人可能是同学关系。他们穿着相似风格的校服，系着同款领带，这种统一的着装通常是学校的标志，表明他们来自同一所学校。两人面带笑容，相处氛围轻松愉快，应该是关系不错的同学。



请识别图中人物关系

图中站在台上的人与台下观众是演讲者与听众的关系。台上的人可能在进行主题演讲、产品发布或知识分享等活动，向台下众多听众传递信息。




Qwen2.5-VL

This WebUI is based on Qwen2.5-VL, developed by Alibaba Cloud.

本WebUI基于Qwen2.5-VL。

Qwen2.5-VL

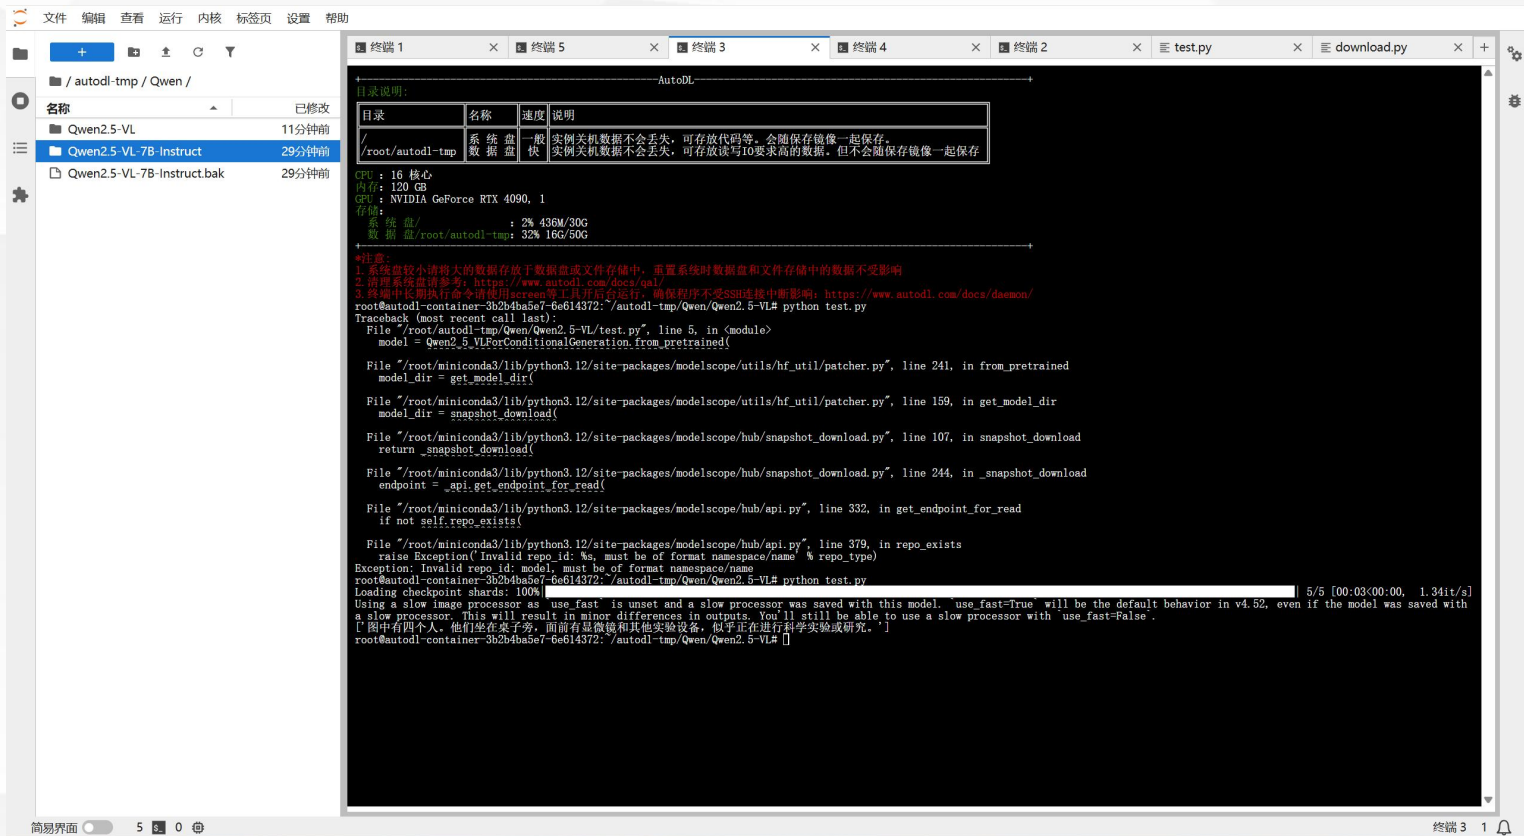


描述一下这张图片

这张图片展示了一个甜品店的内部，分为多个小格子，每个格子里都展示了不同种类的甜点。从上到下，第一行展示了各种

Input

译



致 谢

THANK YOU

感谢您的观看！