



# SocialGPT: Prompting LLMs for Social Relation Reasoning via Greedy Segment Optimization

SocialGPT: 通过贪婪段优化为社交关系推理提示大型语言模型

汇报: *yixuan*

日期: 2025.4.26

# 目 录

01 主要解决的问题

02 先前技术不足

03 核心思想与贡献

04 技术实现细节

05 其他收获

01

# 主要解决的问题

## 一、提升社会关系识别性能

提出 SocialGPT 框架，融合视觉基础模型（VFMs）与大型语言模型（LLMs），实现“感知 + 推理”。VFMs 提取视觉信息转化为文本；LLMs 基于文本和 SocialPrompt 进行推理，为社会关系识别提供强大零样本基线。

- **解决传统方法泛化性差问题**，提高识别准确率。
- **解决传统方法可解释性缺失的问题**，通过 LLMs 输出推理过程，说明判断社会关系的依据，生成可解释的答案。

## 二、优化提示设计与调整

基于 LLM，提出贪婪段提示优化（GSPO）算法用于自动提示调优。


- **解决手动设计提示的低效问题**，通过自动搜索和调整提示，减少人力投入，提高效率。
- **解决自动提示的自由格式目标问题**，GSPO 通过预定义输出格式（如 “The final answer is <label>”），将自由格式文本目标转化为可计算的结构化标签预测，使损失计算可导；
- **解决自动提示的长提示优化难题**，采用段级优化替代令牌级优化，大幅缩小搜索空间，提升 LLMs 推理性能。

## 输入

- 一张图像  $I$ ;
- 两个关注个体的边界框  $b1$ 和 $b2$ 。

## 输出

- 两人之间的社会关系类别  $y$ ;
- 基于文本的解释  $a$ 。



02

先前技术不足

泛化性问题

传统方法依赖特定数据集训练专用模型，难以泛化到新场景或不同风格的图像（如卡通或素描）。

可解释性问题

端到端神经网络模型如同“黑箱”，无法为决策提供清晰的解释，即无法说明依据哪些图像特征得出特定的社会关系判断。

手动设计提示问题

手动寻找最佳提示是耗时且劳动密集的。

长提示优化问题

现有提示优化方法难以处理视觉推理任务中生成的超长文本提示。

自由格式目标问题

传统视觉分类任务输出是离散的独热标签，而转换为 LLM 的生成任务后，输出变成无限制的文本形式，难以定义和计算。

多采用端到端训练神经网络的范式，依赖大量标记图像数据。

社会关系识别方法层面

提示设计与优化层面



泛化性问题

传统方法依赖特定数据集训练专用模型，难以泛化到新场景或不同风格的图像（如卡通或素描）。

可解释性问题

端到端神经网络模型如同“黑箱”，无法为决策提供清晰的解释，即无法说明依据哪些图像特征得出特定的社会关系判断。

新方法在这些新颖图像风格上泛化得很好，并且提供清晰的解释。

多采用端到端训练神经网络的范式，依赖大量标记图像数据。

社会关系识别方法层面



[GRN] <P1>-<P2>: Colleagues  
[Ours] <P1>-<P2>: [The final answer is <classmates>]. Based on the description of the image, the most likely social relationship between <P1> and <P2> is that they are classmates. The setting of a classroom and the presence of other students indicate an educational context. The description does not provide any indication of a familial or romantic ...



[GRN] <P2>-<P3>: grandpa-grandchild  
[Ours] <P2>-<P3>: [The final answer is <father-child>]. Based on the description of the image, the most likely social relationship between <P2> and <P3> is that of a father and child. The presence of a family playing board games in the living room suggests a familial context. The description emphasizes the young age and playful demeanor of <P2>, indicating a child ...

Figure 5: Results when applying SocialGPT to sketch and cartoon images. The images are generated by GPT-4V. Our method generalizes well on these novel image styles.



新提出的GSPO算法对于各模型都有效提升了提示效果方面的效能。

Table 5: Prompt tuning results (accuracy in %) with GSPO.

| Model      | PIPA         |              |          | PISC         |              |          |
|------------|--------------|--------------|----------|--------------|--------------|----------|
|            | SocialGPT    | + GSPO       | $\Delta$ | SocialGPT    | + GSPO       | $\Delta$ |
| Vicuna-7B  | 61.58        | 62.99        | +1.41    | 45.13        | 49.79        | +4.66    |
| Vicuna-13B | <b>66.70</b> | <b>69.23</b> | +2.53    | <b>65.12</b> | <b>66.19</b> | +1.07    |
| Llama2-7B  | 31.91        | 34.07        | +2.16    | 36.71        | 38.04        | +1.33    |
| Llama2-13B | 37.86        | 41.27        | +3.41    | 42.74        | 48.39        | +5.65    |

手动设计提示问题

手动寻找最佳提示是耗时且劳动密集的。

长提示优化问题

现有提示优化方法难以处理视觉推理任务中生成的超长文本提示。

自由格式目标问题

传统视觉分类任务输出是离散的独热标签，而转换为 LLM 的生成任务后，输出变成无限制的文本形式，难以定义和计算。

提示设计与优化层面

03

## 核心思想与贡献

## 核心思想

本文旨在解决当前社会关系识别方法的局限性（可推广性和可解释性），通过融合视觉基础模型（VFM<sub>s</sub>）和大语言模型（LLM<sub>s</sub>）的优势，提出一个简单的模块化框架（SocialGPT），实现高效、可解释的社会关系推理。同时，针对手动提示设计的低效性以及自动提示调整的挑战，引入贪婪段落提示优化（GSPO）算法，以优化提示，提升模型性能。

## 核心贡献

- 1). 提出一个简单的模块化框架，用于社会关系推理的基础模型，这为第一个零-shot社会关系识别方法提供强有力的基线。
- 2). 为解决与视觉推理任务相关的长提示优化问题，进一步提出贪婪段落提示优化，采用梯度引导在段落级别进行贪婪搜索。
- 3). 实验表明，该方法在无需额外模型训练的情况下获得了非常具有竞争力和可解释的零-shot结果。通过GSPO，该方法显著优于最先进的方法。

04

## 技术实现细节






Figure 2: The framework of SocialGPT, which follows the “perception with VFMs, reasoning with LLMs” paradigm. SocialGPT converts an image into a *social story* in the perception phase, and then employs LLMs to generate explainable answers in the reasoning phase with SocialPrompt.



Figure 4: Visualization results of interpretability. We show the SocialGPT perception and reasoning process. We see that our model predicts correct social relationships with plausible explanations.

# 感知阶段

## 01 输入图像I



## 02 图像分割b

- **输入：** 图像I。
- **实现：** 使用**SAM**对图像进行分割。
- **输出：**
  - 获得所有不同的物体掩码；
  - 从掩码的像素坐标导出外接矩形框b；
  - 对每个掩码分配唯一符号，符号与边界框坐标绑定（如 $P1 \leftrightarrow b1$ ）。

## 03 形成说明文字

- **Dense captions（密集描述）：** SAM+BLIP-2生成的碎片化对象描述（如“P1: a man in suit”）。
- **Task-oriented captions（任务导向描述）：** 通过BLIP-2对话功能提取的领域特定信息（如“P1: male, age 40-50”）。
- 合并为孤立描述列表（如“P1: a woman in red (female, 30-40)”）。

## 04 形成社会故事S

- **输入：** 孤立描述列表 + 符号化对象关系。
- **实现：** 指示一个大型语言模型（LLM）作为信息融合工具。采用赋能ChatGPT的GPT-3.5Turbo模型。
- **输出：** 连贯的社会故事S（自然语言段落）。

- 设计四个部分指导LLM生成SocialPrompt。
- **系统** 明确定义社会推理任务的几个核心规则；
- **期望** 设定生成的目标和预期结果；
- **上下文** 提供足够的背景信息；
- **指导** 提供示例，展示如何基于社交故事对查询做出回应。
- 最终SocialPrompt是由(o,r,c,e)组成。
- 观察（Observation）、推理（Reasoning）、类别（Categories）、示例（Examples）。

## 01 生成社会关系推理提示(SocialPrompt)

- **输入：** 边界框b1、b2；社会故事S。
- **实现逻辑：**
  - 边界框b1→符号 P1, b2→符号P2；
  - 直接引用符号构造问题；
- **输出：** 自然语言查询q (What is the social relationship between P1 and P2?) 。

## 02 生成文本查询q

- **输入：** 拼接后的完整提示，SocialPrompt + S + q。
- **输出：** 可解释答案a。

## 03 输出可解释性答案a

# 推理阶段



## 传统提示优化的问题

**1 手动设计的局限性：**传统方法依赖人工设计提示（prompt），过程耗时且结果不稳定。不同表述可能导致大语言模型（LLM）的性能差异显著。

**2 自由形式输出的复杂性：**传统分类任务输出离散标签，而LLM生成的任务输出为自由形式的文本，需额外处理以匹配目标格式（如首句固定为类别答案）。

**3 长提示的挑战：**即使用令牌级优化，在视觉推理任务中，提示通常较长（如超过2000个token），直接优化所有tokens的搜索空间过大，现有方法难以处理。

VS

## 贪婪段落提示优化（GSPO）

**1 段落级优化：**将长提示分为多个段落（如系统指令、任务期望、上下文定义、示例引导），在段落级别进行优化，而非单个token级别，显著降低搜索空间。

**2 梯度引导的贪婪搜索：**

- 为每个段落生成候选集（使用ChatGPT生成，然后轻微的手动修改）。
- 计算段落选择的梯度（基于损失函数），选取梯度下降方向最显著的Top-K候选。
- 迭代替换表现最佳的段落，逐步优化整体提示。

**3 目标函数设计：**通过固定输出首句格式（如“The final answer is <label>”），将自由文本生成任务转化为对类别标签的监督，从而定义可优化的损失函数。



## Algorithm 1 Greedy Segment Prompt Optimization

**Input:** Initial segments  $w_{1:M}$ , training dataset  $\mathcal{T}$ , iteration number  $N$   
Build the candidate set  $\mathcal{W}_m$  for each segment  $w_m$   
**repeat**  $N$  times  
    Randomly sample a batch of data  $\mathcal{D}$  from  $\mathcal{T}$   
    **for**  $m = 1, \dots, M$  **do**  
         $\mathcal{U}_m := \text{Top-}k(-\sum_{z \in \mathcal{D}} \nabla_{h_{w_m}} \mathcal{L}(w_{1:M}; z))$   $\triangleright$  Compute top- $k$  promising segment substitutions  
    **for**  $b = 0, 1, \dots, K * M - 1$  **do**  
         $\tilde{w}_{1:M}^{(b)} := w_{1:M}$   $\triangleright$  Initialization  
         $\tilde{w}_i^{(b)} := \mathcal{U}_i(\lfloor b/M \rfloor)$ , where  $i = (b \bmod M) + 1$   
         $w_{1:M} := \tilde{w}_{1:M}^{(b^*)}$ , where  $b^* = \operatorname{argmin}_b \sum_{z \in \mathcal{D}} \mathcal{L}(\tilde{w}_{1:M}^{(b)}, z)$   $\triangleright$  Select one replacement segment  
         $w_{1:M} := \tilde{w}_{1:M}^{(b^*)}$ , where  $b^* = \operatorname{argmin}_b \sum_{z \in \mathcal{D}} \mathcal{L}(\tilde{w}_{1:M}^{(b)}, z)$   $\triangleright$  Compute best replacement  
**Output:** Optimized segments  $w_{1:M}$

## 算法步骤及作用分析

### 1. 输入与初始化

- **Input:** 接收初始段  $w_{1:M}$  (表示由  $M$  个段组成的初始提示)、训练数据集  $\mathcal{T}$ 、迭代次数  $N$ 。
- **Build the candidate set  $\mathcal{W}_m$  for each segment  $w_m$ :** 为初始提示中的每个段  $w_m$  构建候选集  $\mathcal{W}_m$ 。候选集里包含了可能用来替换当前段的其他选项, 这些选项后续会参与迭代优化过程。

### 2. 外层迭代

- **repeat  $N$  times:** 整个优化过程会重复  $N$  次, 每次迭代都尝试进一步优化提示段组合。
- **Randomly sample a batch of data  $\mathcal{D}$  from  $\mathcal{T}$ :** 从训练数据集  $\mathcal{T}$  中随机抽取一批数据  $\mathcal{D}$ 。这一批数据用于在当前迭代中评估不同提示段组合的效果, 基于这些数据计算损失函数等指标来判断提示的优劣。

### 3. 内层循环1 - 计算候选替换段

- **for  $m = 1, \dots, M$  do:** 遍历初始提示中的每一个段  $w_m$ 。
- $\mathcal{U}_m := \text{Top-}k(-\sum_{z \in \mathcal{D}} \nabla_{h_{w_m}} \mathcal{L}(w_{1:M}; z))$ : 对于每个段  $w_m$ , 计算一个包含  $k$  个最优候选段的集合  $\mathcal{U}_m$ 。这里通过计算损失函数  $\mathcal{L}$  关于  $h_{w_m}$  (可能是与段  $w_m$  相关的隐藏层表示) 的梯度, 并在训练数据子集  $\mathcal{D}$  上求和取反, 找到使损失函数下降最快的  $k$  个候选段。直观来说, 就是找到最有可能替换当前段  $w_m$  并使模型在这批数据上表现更好的  $k$  个段。

### 3. 内层循环1 - 计算候选替换段

- **for  $m = 1, \dots, M$  do:** 遍历初始提示中的每一个段  $w_m$ 。
- $\mathcal{U}_m := \text{Top-}k(-\sum_{z \in \mathcal{D}} \nabla_{h_{w_m}} \mathcal{L}(w_{1:M}; z))$ : 对于每个段  $w_m$ , 计算一个包含  $k$  个最优候选段的集合  $\mathcal{U}_m$ 。这里通过计算损失函数  $\mathcal{L}$  关于  $h_{w_m}$  (可能是与段  $w_m$  相关的隐藏层表示) 的梯度, 并在训练数据子集  $\mathcal{D}$  上求和取反, 找到使损失函数下降最快的  $k$  个候选段。直观来说, 就是找到最有可能替换当前段  $w_m$  并使模型在这批数据上表现更好的  $k$  个段。

### 4. 内层循环2 - 尝试替换并寻找最优

- **for  $b = 0, 1, \dots, K * M - 1$  do:** 进行  $K * M$  次尝试 (这里  $K$  可能是与候选段相关的参数,  $M$  是提示段数量)。
- $\tilde{w}_{1:M}^{(b)} := w_{1:M}$ : 将当前提示段组合  $w_{1:M}$  复制给  $\tilde{w}_{1:M}^{(b)}$ , 作为初始化。
- $\tilde{w}_i^{(b)} := \mathcal{U}_i(\lfloor b/M \rfloor)$ : 从候选段集合  $\mathcal{U}_i$  中选择一个段来替换  $\tilde{w}_{1:M}^{(b)}$  中的第  $i$  个段。其中  $i = (b \bmod M) + 1$ , 通过取模运算确定要替换的段的索引,  $\lfloor b/M \rfloor$  用于从候选段集合  $\mathcal{U}_i$  中选择合适的候选段。
- $w_{1:M} := \tilde{w}_{1:M}^{(b^*)}$ , where  $b^* = \operatorname{argmin}_b \sum_{z \in \mathcal{D}} \mathcal{L}(\tilde{w}_{1:M}^{(b)}, z)$ : 在所有尝试  $b$  中, 找到使在训练数据子集  $\mathcal{D}$  上损失函数  $\mathcal{L}$  最小的那个提示段组合  $\tilde{w}_{1:M}^{(b^*)}$ , 并将其赋值给  $w_{1:M}$ , 即确定本次迭代的最优提示段组合。

### 5. 输出

- **Output:** Optimized segments  $w_{1:M}$ : 经过  $N$  次迭代后, 输出优化后的提示段组合  $w_{1:M}$ , 该组合理论上能使模型在相关任务上基于训练数据有更好的表现。

# 范例

## SocialPrompt 范例：家庭聚会上的人物关系推理

### Social Story

在一间温馨的客厅里，一位白发老人坐在沙发中央，脸上洋溢着幸福的笑容。左侧，一位中年女性正弯腰靠近老人，手里端着一盘切好的水果，轻声和老人交谈。沙发右侧，一个年轻男子抱着一个小男孩，小男孩兴奋地指着茶几上的生日蛋糕，年轻男子满眼宠溺地看着孩子。茶几旁，一位中年男性正起身准备给大家倒水，他的动作自然而亲切。客厅的墙上挂着几张家庭合照，天花板上悬挂着彩色气球，整个场景充满欢乐与温馨。

### Social Prompt

观察（**Observation**）：请仔细分析这张家庭聚会的图片，注意人物的年龄、外貌、动作、表情以及周围环境等细节。

推理（**Reasoning**）：根据观察到的信息，运用你的知识和逻辑推理能力，思考这些人物之间可能存在的社会关系。

类别（**Categories**）：本次推理的社会关系类别包括但不限于祖孙关系、父母与子女关系、夫妻关系、兄弟姐妹关系。

示例（**Examples**）：

- 示例1：在另一张家庭聚会照片中，一位老年男性坐在主位，旁边的中年女性正帮他整理衣服，根据年龄、动作及亲密的氛围，可推理中年女性是老年男性的女儿。
- 示例2：一张生日聚会图片里，年轻夫妇抱着孩子，孩子开心地吹着蜡烛，结合场景和人物互动，能判断出他们是亲子关系。

### Question

在这张家庭聚会图片中，白发老人与中年女性、年轻男子、中年男性、小男孩之间分别是什么关系？请详细说明你的推理依据。

05

其他收获

## 难点解释

**令牌 (token)** 是文本处理中的基本单位，一段文本会被拆分成多个令牌。（以 “I like apples” 为例，可能被拆分成 “I” “like” “apples” 这几个令牌。）**令牌级优化**就是针对这些单个令牌进行的优化操作，在大语言模型中，通过调整与每个令牌相关的参数或设置，让模型在处理和生成文本时表现更优。在训练语言模型时，令牌级优化可以让模型更好地学习每个令牌的语义和上下文信息，提升语言理解和生成能力。

**在文本中的问题：**在对提示进行调整时，令牌级优化针对单个令牌逐一处理，规模极其庞大。而段级优化以段为单位，考虑的是一段文本的整体作用 and 影响，更符合人类对文本的理解和处理方式，也更适合处理长提示的优化问题。

**端到端训练神经网络的范式** “端到端” 意味着从输入到输出，整个过程**由一个神经网络直接完成**，不需要人为手动设计中间步骤。就好比搭建一座从起点到终点的桥梁，神经网络就是这座桥，输入数据从桥的一端进入，直接从另一端输出结果，中间的复杂计算和转换都在神经网络内部自动进行。

**在文本中的问题：**在社会关系识别里，输入的是图像数据（比如一张包含多个人物的照片），输出的是图像中人物之间的社会关系（如朋友、家人、同事等）。训练这个神经网络时，会给它大量的图像以及对应的人物关系标签，让网络学习图像特征和社会关系之间的联系。数据量越大，它能学习到的规律就越准确、越全面。因此，该模型依赖大量标记图像数据，泛化力差、可解释性弱。

# 难点解释

**热标签 (Hot Label)** 热标签 = 传统标签 (如 One-Hot) + 额外结构化信息 (如坐标、固定模板)。在论文中, GSPO通过固定输出格式 (如首句 "The final answer is <label>"), 将 LLM 的**自由文本生成任务**转化为**结构化标签预测**, 从而:

- 使损失计算可导 (监督首句的 token 概率)。
- 避免模型生成无关内容, 提升推理准确性。

这种设计可以看作是一种“热标签”策略, 因为它不仅包含类别信息, 还强制模型按特定格式输出, 优化了训练目标。

**独热编码 (One-Hot Encoding)** 将离散型特征 (categorical variables) 进行编码的方式, **把每个类别映射为一个唯一的二进制向量**。例如, 对于水果类别 (苹果、香蕉、橙子) 进行独热编码, 苹果就是 [1, 0, 0], 意思是 “我是苹果, 不是香蕉也不是橙子”; 香蕉是 [0, 1, 0], 代表 “我是香蕉, 不是苹果和橙子”; 橙子是 [0, 0, 1], 表示 “我是橙子, 不是苹果和香蕉”。每个位置上只有一个 “1”, 其他都是 “0”, 这就是 One-Hot 编码名字的由来, “One” 代表那个唯一的 “1”, “Hot” 形容这个 “1” 很突出、很特别。



# 难点解释

**0-shot** 即零样本学习（Zero - Shot Learning，简称 ZSL），是机器学习领域的概念。传统机器学习需大量标注样本训练模型，模型学习训练样本特征后对相似样本分类预测。零样本学习中，模型在训练时未见过要预测类别的任何样本，借助辅助知识（如类别描述、属性信息等），基于已有知识进行推理，实现对新类别对象的分类识别。例如：模型认识马、老虎、熊猫，没见过斑马，但被告知斑马有马的轮廓、老虎般条纹、熊猫的黑白色，就能识别斑马。

## 常见应用场景及优势：

- 图像识别：在识别新发现物种、罕见物品等缺少大量标注样本的情况下，零样本学习可让模型快速识别。如生态研究中识别新记录物种图像。
- 自然语言处理：处理新出现词汇、短语语义理解和分类任务，像及时处理网络新热词。
- 医疗诊断：辅助诊断罕见病。因罕见病病例少、标注数据稀缺，零样本学习能基于已有疾病知识和罕见病特征描述进行诊断推测。

**在本文的应用：**文章提出的 SocialGPT 框架将视觉基础模型（VFM）和大语言模型（LLMs）相结合。VFM 负责将图像信息转化为文本形式，LLMs 基于这些文本信息以及特定的提示（SocialPrompt）进行社会关系推理。在这个过程中，不需要针对特定的社会关系场景使用大量标注图像数据来训练模型，而是利用已有的预训练模型知识，直接对新的、未见过的图像中的社会关系进行推理，为社会关系识别提供了强大的零样本基线。

## 与此相关：

- One - Shot Learning（一样本学习）：给模型一个新类别的单个样本，模型据此学习并识别该类其他样本。
- Few - Shot Learning（少样本学习）：用少量新类别样本训练模型，使其具备识别该类更多样本能力。

# 难点解释

**贪婪解码 (Greedy Decoding)** 语言模型生成文本时采用的一种简单直接的解码算法。在自回归语言模型生成文本过程中，每一步都基于前文语境预测下一个词元 (token)。贪婪解码会在每一步直接选择概率最高的词元作为输出。它不会考虑后续步骤或整体文本的最佳性，只关注当下最有可能的选择，一步步生成文本，直至满足结束条件（如达到预设长度或生成结束标记）。比如：模型预测下一个词时，候选词有“苹果”“香蕉”“橘子”，对应概率分别为 0.5、0.3、0.2，贪婪解码就会选择“苹果”。

**温度参数：**温度 (temperature) 是影响文本生成的一个参数，取值范围通常在 0.0 - 2.0 之间。它类似 top - k 和 top - p 采样值，会影响模型输出词元 (token) 的概率分布。**温度值较高时**，会使不同词元被选择的概率趋于平均，让低概率词元有更多机会被选中，增加生成文本的随机性和创造性；**温度值较低时**，高概率词元被选中的概率会进一步放大，文本生成更具可预测性。

一般来说，温度越低，生成结果越确定，越接近贪婪解码。当温度为 0 时，模型会选择每个步骤中概率最高的词作为输出，这是一种极端的贪婪解码方式，完全不考虑其他概率较低的候选词，生成的文本相对较为保守和确定。（在本文中，将温度设置为 0 以进行贪婪解码。）

## 贪婪解码的优势：

- 简单高效：计算逻辑简单，易于实现。无需复杂计算或评估大量选项，在对响应时间要求较高的场景（如实时问答系统）中，能快速生成结果，减少延迟。

# 难点解释

## 贪婪解码的局限性：

- 缺乏多样性：总是选择概率最高词元，易使生成文本单调、重复，缺乏新意。
- 易陷局部最优：仅依据当前步骤最优选择，忽视其他潜在更优组合，导致生成文本在整体语义、逻辑连贯性等方面存在缺陷，无法达到全局最优。
- 鲁棒性较差：对少见但合理的表达组合不敏感，遇到复杂语境或需灵活处理的情况时，表现欠佳。

**在本文中：**贪婪解码结合了**特定的提示设计和贪婪段提示优化（GSPO）算法**来提高社会关系推理的准确性和效果。

- 与特定提示设计结合：文中使用了 SocialPrompt 来引导语言模型进行社会关系推理。在贪婪解码过程中，基于这些精心设计的提示，模型能够更准确地根据输入信息生成关于社会关系的推理结果。例如，通过在提示中包含图像的文本描述以及相关的问题引导，让贪婪解码能够聚焦于社会关系的判断，而不是生成与任务无关的内容。
- 与 GSPO 算法结合：文章提出的 GSPO 算法用于优化提示，虽然不是直接作用于贪婪解码，但为贪婪解码提供了更好的输入提示。通过预定义输出格式、将自由格式目标转化为可计算的结构化标签预测，以及采用段级优化缩小搜索空间等操作，使提示更适合语言模型进行零样本的社会关系推理，从而间接提升了贪婪解码在该任务中的性能。

感谢您的观看！

P l e a s e   C r i t i c i z e   A n d   C o r r e c t