



MULTI-GRANULARITY REASONING FOR SOCIAL RELATION RECOGNITION FROM IMAGES

多粒度推理用于从图像中识别社会关系

汇报: *yixuan*

目录



1 主要解决的问题

2 先前技术不足

3 核心思想与贡献

4 技术实现细节

5 其他收获



主要解决的问题

如何通过互补的多粒度信息实现社会关系识别

多粒度：（以该图为例）

- 全局粒度（场景信息）

Stress


- 中粒度（人物与物体的区域）

Person A、Person B、Bag、Car A、Car B、Car C


- 细粒度（人-人互动、人-物互动）

上图：Person A $\rightleftharpoons$ Person B、Person B $\rightleftharpoons$ Bag


下图：Person A $\rightleftharpoons$ Bag、Person A $\rightleftharpoons$ Car A、
Person B $\rightleftharpoons$ Car B



输入、输出



输入： 包含多个人物的图像



输出： 对图像中人物对的社会关系进行分类（如朋友、家人、同事等）。



先前技术不足

1

单一特征依赖

传统方法**仅依赖单一特征**（如人脸表情、身体外观或上下文物体），无法全面捕捉多粒度的语义信息。

- Zhang et al.: 仅通过人脸图像学习社会关系特征。
- Sun et al.: 基于社会领域理论提取一组属性（如性别、年龄、服装等），但未建模交互信息。

2

忽略交互信息

现有方法**仅考虑人物与物体的共存关系**，而忽略了动作和姿态交互。

- Wang et al.: 提出基于共存的图模型，但未利用姿态信息建模交互。
- Li et al.: 双瞥模型（Dual-glance）关注人物和上下文物体，但未显式建模人物-物体动作或人物间交互。

3

全局与局部信息割裂

先前方法**未有效结合全局场景信息和局部区域特征**。

- Union-CNN: 仅通过人物联合区域识别关系，缺乏全局场景理解。
- Two-stream CNN: 仅关注人体和头部区域，未利用场景或交互信息。



核心思想与贡献

核心思想

提出了一种**多粒度推理框架**（Multi-Granularity Reasoning, MGR），通过结合不同粒度的信息来弥合视觉特征与社会关系之间的领域差距。

- **全局粒度**：使用CNN提取整个场景的全局特征。
- **中粒度**：通过目标检测提取人物和物体的区域特征。
- **细粒度**：利用人物姿态关键点构建人物-物体图（Person-Object Graph, POG）和人物-姿态图（Person-Pose Graph, PPG），建模人物与物体之间的动作以及人物之间的交互。
- **图卷积网络（GCN）**：在构建的图上进行关系推理，通过消息传播机制将视觉特征映射到社会关系语义。

VS

核心贡献

- 提出MGR框架，旨在弥合视觉特征与社交关系之间的领域差距，以便在图像中进行社交关系识别。
- 设计了一个POG来建模从人到物体的动作，同时设计了一个PPG来建模由人类姿势引导的人员之间的交互。在图上，通过GCNs执行从视觉到语义领域的推理。
- 该框架在两个公共数据集上获得了最先进的结果，证明了方法的有效性。



技术实施细节

多粒度特征融合框架

通过分层提取全局、中观、细粒度特征，覆盖**场景、区域与交互**多维度信息。

1

全局粒度：场景语义捕捉

采用 ResNet-101 提取整图特征，学习场景级知识（如办公室、家庭）对关系的提示作用。

2

中观粒度：区域特征与物体关联

使用目标检测模型（如 Mask R-CNN）定位人物与物体区域，提取 CNN 特征作为中层次语义（如人物服装、物体类别）。

3

细粒度：姿势引导的交互建模

- 人物 - 物体图 (POG)：通过姿势关键点与物体的交叠 (IoU) 建立连接，建模人物对物体的动作（如 “手持包” “操作电脑”）。
- 人物 - 姿势图 (PPG)：利用骨架关键点的自然连接（如手肘 - 手腕）及跨人物主动关键点（如手腕、脚踝）的距离加权连接，捕捉人物间的互动紧密程度（如牵手、并肩站立）。




Fig. 2. The overall framework of the Multi-Granularity Reasoning framework.

分支1 全局特征学习分支

- **输入：**原始图像作为输入。
- **全局特征提取：**采用深度卷积神经网络（ResNet-101）对整图进行特征提取，学习场景级语义（如办公室、家庭等）。
- **输出：**全局特征向量，经全连接层（FC Layer）生成场景相关的初步分类分数（Scores），反映场景对关系的先验提示（如办公室场景暗示“同事”关系）。

分支2 姿势引导的图推理分支

(1) 目标检测与区域特征提取

- **人物与物体定位：**使用Mask R-CNN等目标检测模型，识别图像中的人物边界框和物体边界框，保留高置信度的前 5 个物体。
- **区域特征提取：**
 - 人物特征：通过 ResNet-101（在人物图像上预训练）提取 2048 维特征。
 - 物体特征：通过 ResNet-101（在 ImageNet 上预训练）提取 2048 维特征。

(2) 人体姿势估计与关键点提取

- **关键点检测：**采用MS-COCO 姿态估计模型，为每个人物生成 17 个骨架关键点（如鼻子、手腕、脚踝），每个关键点包含位置坐标和置信度分数。
- **关键点特征编码：**将每个关键点编码为 30 维向量（包含位置和热图置信度），作为细粒度交互建模的基础。

分支2 姿势引导的图推理分支

(3) 图模型构建与 GCN 推理

● 人物 - 物体图 (POG) :

- 节点：源于人的边界框 P_i 和物体 O_j ，人物节点的数量为三（有两个人和他们的一个联盟）、物体节点 M 个，共 $3+M$ 个节点。
- 边：

人物 - 物体边：通过人物姿势关键点与物体的交叠 (IoU) 建立连接，反映人物对物体的动作（如携带包）。

人物 - 人物边、物体 - 物体边：全连接（边权为 1），建模区域内的共存关系。

● 人物 - 姿势图 (PPG) :

- 节点：源于人体骨骼关键点，两人共 34 个关键点（每人 17 个）。
- 边：

同人物关键点：按骨骼自然连接（如手肘 - 手腕），边权为 1。

跨人物关键点：活动节点（鼻子、手腕、脚踝）与对方所有节点连接，边权为 $(2 - \text{归一化欧氏距离})$ ，距离越近权值越高，量化交互紧密程度（如牵手时手腕距离近，权值接近 2）。

● GCN 推理：

对 POG 和 PPG 分别应用多层 GCN，通过消息传播机制更新节点特征，捕捉“人物 - 物体动作”和“人物间姿势交互”的语义。最后，经全连接层生成交互相关的分类分数。



其 他 收 获

难点理解

图卷积网络 (Graph Convolutional Network, GCN)

一种对图结构数据进行深度学习的模型。在 POG 和 PPG 上应用 GCN，通过消息传播机制更新图中节点特征，实现从视觉特征到社交关系语义的推理，挖掘图结构中节点间的隐含关系。

GCN的传播公式：

$$X^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X^{(l)} W^{(l)}),$$

1.输入：

- 当前层特征 $X^{(l)}$ (N个节点，每个节点d维特征)。

- 归一化邻接矩阵 $A = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$

2.矩阵乘法： $\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X^{(l)}$

- 聚合邻居特征。

3.权重变换： $\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X^{(l)} W^{(l)}$

乘可学习参数W，映射到新的特征空间。

4. 非线性激活： $X^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X^{(l)} W^{(l)}),$

通过 （如ReLU）引入非线性，得到更新后的特征 $X^{(l+1)}$ 。

5.输出：节点的新特征，包含自身及其关联节点的信息。

难点理解

信息传播机制

图卷积网络（GCN）在人物 - 物体图（POG）和人物 - 姿势图（PPG）上运行时，节点间交换信息的过程。即各节点将自身特征作为信息传递给相连节点，同时聚合接收来自邻居节点的信息，**不断更新自身特征表示**，以此挖掘人物与物体交互、人物间姿势关联等语义，助力社交关系推理。

交并比 (Intersection over Union, IoU)

一种衡量两个边界框（如人物姿势关键点框与物体框）重叠程度的指标。计算方式为两个边界框交集面积与并集面积之比，用于判断人物姿势关键点与物体是否存在关联，进而在 POG 中建立连接。

Mask R - CNN

一种**目标检测模型**，在 Faster R - CNN 基础上扩展，能同时进行目标检测和实例分割，即不仅能定位图像中的目标物体（如人物、物体），还能对每个目标进行像素级的分割，文中用于定位人物和物体区域并提取特征。

残差网络 (Residual Network, ResNet)

一种**深度卷积神经网络架构**，通过引入跳跃连接（Skip Connection），允许网络学习残差映射，有效缓解了深度网络训练中的梯度消失问题，使得可以训练超深层网络，文中用于图像特征提取。

数据集总结

一、PISC 数据集 (People in Social Context)

- 数据来源与场景：聚焦于日常生活中的社交关系，包含多种常见场景（如街头、家庭、办公室等）。图像中人物对的关系标注基于真实社交场景，覆盖亲密与非亲密关系。
- 关系类别：包含6类细粒度关系：朋友 (Friend)、家人 (Family)、情侣 (Couple)、职业 (Professional)、商业 (Commercial)、无关系 (No Relation)。
- **评估指标：**

单类别准确率 (Top-1 Accuracy)： 衡量每个关系类别的分类精度。

平均精度均值 (mAP, mean Average Precision)： 综合评估所有类别性能的核心指标。

二、PIPA 数据集 (People in Photo Album)

- 数据来源与场景：基于社会领域理论 (Social Domain Theory) 标注，模拟家庭相册中的人物关系场景，强调社会角色与互动模式。
- 关系类别：包含16类社交关系，覆盖更广泛的社会角色。
- **评估指标：整体准确率 (Accuracy)：** 衡量所有关系类别的平均分类精度。

三、MS-COCO数据集 (Microsoft Common Objects in Context)

- 包含超过 33 万幅图像，标注了80类目标物体、91类 stuff (背景材质) 和**人体关键点**。
- 人体关键点标注覆盖17个部位（如鼻子、眼睛、耳朵、四肢关节等），适用于姿势估计任务。



总结各论文缺陷

论文题目：MULTI-GRANULARITY REASONING FOR SOCIAL RELATION RECOGNITION FROM IMAGES

存在缺陷：

一、基础模型架构与性能方面

- **复杂场景适应性有限：**现实场景复杂多样，图像中的遮挡、光线变化等因素会干扰模型对人物、物体特征及相互关系的判断。文中虽考虑多粒度信息，但在复杂场景下，如人群密集且存在遮挡的音乐会现场，模型可能难以精准识别个体的姿态关键点，进而影响POG和PPG的构建，导致社会关系推理出现偏差。
- **粒度信息融合不够深入：**虽然融合了全局、中层和细粒度信息，但各粒度信息融合方式相对简单，只是将全局特征和推理得到的特征进行加权融合。这种融合方式可能无法充分挖掘不同粒度信息间的潜在联系，难以发挥多粒度信息的最大优势。
- **缺乏动态关系建模：**主要针对静态图像进行社会关系识别，未考虑视频等动态数据中社会关系随时间的变化。在实际应用中，动态关系包含更丰富的信息，如人物间互动的顺序和持续时间等，而此模型无法处理这些信息，限制了其在动态场景中的应用。

二、数据方面

- **数据集规模小、多样性不足、社会关系类型分布不均衡：**
 1. 论文仅依托PISC和PIPA两个公共数据集展开实验。从规模上看，这两个数据集相对有限，无法充分覆盖现实世界中复杂多元的社会关系场景。例如，对于一些特定文化背景下独有的社会关系，像某些部落文化中特有的亲属关系，或者特定职业领域内的紧密协作关系，可能在数据集中缺失。
 2. 此外，数据集中社会关系类型的分布可能存在不均衡现象。常见的如“朋友”“家人”这类关系可能样本丰富，模型能够充分学习其特征；但像“商业伙伴”“导师与学生”等相对不那么高频出现的关系，样本量可能较少，导致模型对这些关系特征的学习不够充分。当面对包含此类关系的图像时，模型难以精准提取关键特征，进而影响识别准确率，无法有效推广到更广泛的实际应用场景中。

三、实验设计方面

- **消融实验不够全面：**消融实验虽探究了各模块作用，但未涵盖所有可能的组合情况。例如，未测试不同的全局特征提取网络对模型性能的影响，也未研究POG和PPG中不同连接方式或参数设置的效果。

论文题目: SocialGPT: Prompting LLMs for Social Relation Reasoning via Greedy Segment Optimization

存在缺陷:

一、基础模型架构方面

- **视觉基础模型的局限性:** 论文高度依赖 SAM 和 BLIP-2 进行图像分割和 caption 生成, 但 SAM 在复杂场景下可能过度分割对象 (如将一个人分割为多个部位), 导致密集 caption 碎片化, 影响后续社会故事的连贯性。此外, BLIP-2 生成的文本可能遗漏关键社会线索 (如微妙的肢体语言或文化符号), 导致 LLM 推理时信息缺失。
- **LLM 的偏见与逻辑局限性:**
 1. LLMs (如 Vicuna、GPT-3.5) 从海量文本中学习, 可能继承社会偏见、刻板印象或文化偏差。例如, 模型认为“穿西装的人”更可能是“同事”而非“朋友”; “抱孩子的人”默认推断为“母亲”而非“父亲”。
 2. LLM 生成的解释可能看似合理, 但并非基于真实的视觉证据或逻辑链条, 而是依赖文本连贯性或常识假设, 即“解释幻觉”, 导致**解释的表面性与不可靠性**。例如, 模型可能错误地将“同事”关系归因于“共同使用电脑”, 而真实依据是“办公室场景”, 但caption中未明确提到电脑。
- **多阶段流程的误差累积:** 从图像分割、caption 生成到 LLM 推理的多阶段流程中, 前一阶段的错误 (如 SAM 分割遗漏关键对象; 视觉特征经 BLIP-2 压缩为文本后, 部分细节 (如肢体语言、物体空间关系) 可能丢失) 会逐层传递。例如, 若未检测到“婚礼戒指”这一关键物体, LLM 可能无法识别“夫妻”关系。

二、数据方面

- **数据集规模小、多样性不足、社会关系类型分布不均衡:** 同前篇论文。

三、实验设计方面

- **零样本设置的泛化性争议:** 尽管强调零样本性能, 但 GSPO 优化依赖训练数据生成 prompt 候选, 本质上利用了数据分布信息, 可能夸大实际零样本能力。此外, 对素描、卡通图像的测试仅通过 GPT-4V 生成样本, 缺乏真实跨模态数据验证。
- **对比实验的不全面性:** 未与近年新兴的端到端多模态模型 (如 Flamingo、MiniGPT-4) 对比, 难以全面评估 SocialGPT 的竞争力。

论文题目: **Social Relation Recognition from Videos via Multi-scale Spatial-Temporal Reasoning**

存在缺陷:

一、基础模型架构方面

- **Triple Graphs 的节点特征依赖手工设计:** IntraG、InterG 和 POG 的构建依赖 Mask R-CNN 检测结果和余弦距离阈值, 对遮挡、低分辨率或复杂运动场景中的人物与物体检测鲁棒性不足。例如, 当人物在视频中快速移动导致检测框不连续时, IntraG 可能无法准确关联同一人物的不同帧节点。
- **视觉线索的单一性局限:** 明确仅使用视觉模态, 未探索多模态融合, 复杂场景中信息源不足。若应用于多人物场景, 视觉线索可能饱和 (如服装颜色、动作重叠), 则需结合音频 (如对话内容) 或文本 (如屏幕文字) 辅助推理。

二、数据方面

- **ViSR 数据集的场景覆盖有限:** 尽管包含 8 类关系, 但主要从 200 部电影中采集, 可能存在“电影场景偏见” (如戏剧化互动多于真实生活场景), 导致模型在真实监控、家庭视频等场景中泛化能力不足。此外, 数据集仅包含 10-30 秒的短片段, 难以捕捉长时序的关系演变 (如从“陌生人”到“朋友”的过程)。

三、实验设计与性能方面

- **消融实验的不全面性:** 消融实验仅测试 Triple Graphs 的组合, 但未单独验证每个图对特定关系的贡献。例如, POG 对“服务”关系 (如顾客 - 服务员) 的物体依赖 (如餐桌、商品) 至关重要, 但实验未量化其独立影响。
- **实时性不足:** 模型需先通过 Mask R-CNN 检测人物 / 物体 (每帧约 200ms), 再构建 Triple Graphs 并进行 PGCN 推理, 整体延迟较高, 难以满足实时应用 (如直播场景的实时关系分析)。

论文题目：A Domain Based Approach to Social Relation Recognition

存在缺陷：

一、基础模型架构方面

● 社会理论的浅层应用：

1. 虽基于 Bugental 的域理论划分关系，但仅将理论用于标签分层，未将域内属性（如“Attachment 域”的“年龄差异”“保护行为”）显式编码到模型架构中。例如，模型依赖视觉特征（如年龄、服装）间接推断关系，而非直接利用理论定义的行为模式。
2. 未验证理论的跨文化普适性，假设理论适用于所有数据集场景，但不同文化中“Hierarchical power 域”的视觉表现可能差异显著（如东西方职场着装规范）。

● 特征工程的局限性：

1. 依赖手工设计的语义属性（如年龄、性别、proximity），部分属性（如“面部吸引力”）难以通过视觉准确量化。
2. 双流 CNN 模型（CaffeNet）未充分利用上下文信息，如场景中的物体（如“会议室 + 投影仪”暗示“同事”），仅通过人物区域特征推理，导致环境线索利用率不足。

二、数据方面

● 标签模糊性与文化偏差：

1. 数据集中部分关系定义依赖主观判断，导致标注者间一致性较低；
2. 标注者来自不同文化背景，可能对同一关系产生不同理解，但论文未系统性分析文化偏差对模型的影响。

● 样本分布不均衡：尽管包含 16 类关系，但部分类别（如“舞者团队”）样本量较少，模型可能对低频关系过拟合。

- **依赖单模态图像与静态、常规场景：**

1. 完全忽略音频、文本等辅助信息，仅依赖视觉特征，限制了复杂场景的推理能力；
2. 仅使用静态图像，忽略视频中动态交互线索（如对话、动作序列），导致无法捕捉“师徒教学”等需要时间维度信息的关系；
3. 场景覆盖偏向家庭、工作等常规环境，缺乏极端场景（如灾难救援中的临时协作关系）的数据，影响模型泛化能力。

三、实验设计与性能方面

- **对比实验的片面性：**仅与早期图像级方法（如双流 CNN、GRM）对比，未纳入同期先进模型（如基于 Transformer 的视觉 - 语言模型），难以评估竞争力。

- **可解释性的表面化：**

1. 虽通过属性重要性分析（如图 6）展示“活动”“服装”的高贡献度，但未明确属性与关系的因果链条。例如，“穿制服”与“同事”的关联可能受场景干扰（如“演员 - 导演”也可能穿制服），但模型无法区分。
2. 可视化案例（如图 7）仅展示正确预测，未分析误判案例的特征混淆原因（如“情侣穿同款服装被误判为同事”），缺乏对失败模式的深入诊断。

论文题目：From a Social Cognitive Perspective: Context-aware Visual Social Relationship Recognition

存在缺陷：

一、基础模型架构方面

- **CLIP 模型的局限性：**模型高度依赖 CLIP 的预训练语义知识（如 MSAT 模块融合 CLIP 特征），但 CLIP 的性能可能受限于其训练数据中的社会关系覆盖度。例如，某些文化特定的社会符号（如传统婚礼服饰）可能未被 CLIP 充分学习，导致模型在跨文化场景中泛化能力不足。
- **参数共享的潜在风险：**多模态侧适配器（MSAT）通过参数共享实现跨模态对齐，但可能导致视觉和语言分支的语义相互干扰。例如，当文本提示包含噪声时，共享参数可能放大语言分支的误差，影响视觉特征的学习。
- **社会理论整合的深度不足：**引用了社会关系理论（如四种基本原型），但模型设计中对社会属性（如传递性、对称性）的利用较为浅层（仅通过人际推理模块建模），未深入结合社会学理论构建更严谨的关系推理框架。

二、数据方面

- **跨数据集泛化性验证不足：**模型仅在两个特定数据集（PIPA和PISC）上进行测试，未验证在其他视觉社会关系数据集或跨领域场景（如新闻图片、监控视频）中的泛化能力。

三、实验设计与性能方面

- **消融实验的覆盖不全：**消融实验中未测试“社会提示构建”与“跨模态融合策略”的联合影响，例如不同文本模板（如是否包含情感词汇）对模型性能的具体贡献尚未明确。



感 谢 聆 听