

论文阅读梳理

论文题目: Toward Grouping in Large Scenes With Occlusion-Aware Spatio-Temporal Transformers

利用遮挡感知时空变换器实现大场景分组



...

汇报: yixuan

日期: 2025.7.2



目 录

- 01 主要解决的问题
- 02 现有技术缺陷
- 03 核心思想与贡献
- 04 具体技术路线
- 05 其他



01



主要解决的问题

...

01 主要解决的问题

问题1

- 如何应对大规模多人场景中频繁的遮挡问题？

问题2

- 如何有效融合时空信息，挖掘两者间的关联？

01 输入输出

输入



Input video

输入原始视频数据Input video: 包含大规模或小规模场景中的多个人群动态信息，在处理过程中会被分解为一系列帧，从这些帧中提取个体的外观特征（通过预训练 ResNet50）和轨迹特征（基于连续帧中个体的位置变化等）。

输出



Output results

Trajectory ↑ ↑ ↑ ↑ ↑
Person node ● ● ● ● ●

输出Output results: 清晰呈现哪些人属于一个群体，以及他们的运动轨迹。

- Person node（人物节点）：不同颜色标记不同群体；
- Trajectory（轨迹）：箭头展示运动路径；



02



现有技术缺陷

...

02 现有技术缺陷

特点：主要基于手工特征检测人群中的F-formation，通过识别群体的**交互空间**来划分群体。

缺陷：

- 仅关注F-formation这一种空间模式，忽略了其他可能的群体空间结构。
- 依赖单张图像的静态信息，而现实中人际关系具有动态性，单帧结果可靠性低。
- 依赖手工设计的特征和复杂的交互空间检测规则，泛化能力有限。

特点：随着Panda等大规模数据集的出现，研究者开始探索大规模场景的群体检测，采用全局到局部的框架融合图像和轨迹特征。

缺陷：

- 未有效处理群体场景中频繁的**遮挡问题**，遮挡帧的外观特征不可靠，影响检测精度。
- 图像特征与轨迹特征独立提取，**时空信息缺乏同步融合**，导致关联挖掘不足。

小规模场景 + 单一图像阶段

小规模场景 + 视频阶段

大规模场景 + 视频阶段

特点：开始利用视频的时间信息，部分方法（如基于I3D网络）直接输入视频片段同时提取时空特征，或基于轨迹信息进行群体检测。

缺陷：

- **基于视频片段的方法**未充分分离时空特征学习过程，与人类认知不同，导致两者难以被有效学习。
- **基于轨迹的方法**忽略了图像中的人际交互信息。
- 设计初衷为小规模短视频，在大规模场景中计算成本过高，无法适用。



03



核心思想与贡献

...

03 核心思想与贡献

核心思想

针对大规模场景中群体检测面临的**频繁遮挡和时空信息难以有效利用**的问题，提出了端到端的GroupTransformer 框架。

- ① 通过**遮挡编码器**识别并抑制严重遮挡帧的特征，提升个体特征提取的鲁棒性；
- ② 设计**时空 Transformer (STT)**，采用时间分支和空间分支分层融合外观与轨迹特征，实现时空信息的同步处理；
- ③ 通过**边缘分类器**将隐含关联转化为明确群体关系判断的分数，最终实现大规模场景下精准的群体检测。

核心贡献

- 提出端到端的框架，融合来自多模态输入的时空信息，以在大型多人场景中检测群体，这有效地探索多模态信息，并很好地处理了遮挡问题。
- 提出时空变换器，包含一个空间分支和一个时间分支，方便外观和轨迹特征的层次融合。
- 为进一步增强个性化特征提取过程，提出一种遮挡编码器。该组件有效抑制特定帧中受到严重遮挡影响的特征，从而提高我们模型的抗遮挡能力。
- 在大型和小型基准数据集上的实验结果显示出提出的方法的优越性能。






04




具体技术路线

...



A.遮挡编码器



输入：某个人物的连续帧的静态外观特征 $X=[x_1,x_2,...,x_T]$

输出：经过遮挡处理的优化后外观特征 $Z_{app}=[z_1, z_2,..., z_T]$

过程：

• **步骤 1：计算帧间相似度 $S_{i,j}$ （识别遮挡）**
$$s_{i,j} = \frac{f(x_i) f(x_j)^T}{\|f(x_i)\| \|f(x_j)\|}$$

非遮挡帧： $S_{i,j}$ 接近 1（特征相似）；

严重遮挡帧： $S_{i,j}$ 接近 0（特征差异大）。

• **步骤 2：生成注意力权重 a_i （标记遮挡）**
$$a_i = \frac{1}{T} \sum_{j=1}^T s_{i,j}$$

非遮挡帧： a_i 较大（高可靠性）；

严重遮挡帧： a_i 较小（低可靠性）。

• **步骤 3：过滤遮挡特征（抑制噪声）**
$$z_i = g(x_i) \times a_i$$


遮挡帧的特征被弱化，非遮挡帧的特征被保留

针对问题：大规模场景中**频繁遮挡**导致人物特征不可靠

设计目标：过滤严重遮挡帧的噪声特征

核心思想：同一人物的非遮挡帧特征具有高相似度,严重遮挡帧特征与其他帧差异大。通过计算帧间相似度生成注意力权重，弱化遮挡帧的影响。

B.时空



针对问题： 时空信息缺乏同步融合问题

设计目标： 同时捕捉视频中人物的空间关联

（如位置、外观相似性）和时间关联（如轨迹、动态交互）

核心思想： 通过双分支（Spatial Branch + Temporal Branch）分别建模空间关联和时间关联，最后用注意力机制强化群体关系。

输入：

- （空间分支）来自Occlusion Encoder的优化后外观特征 Z_{app}
- （时间分支）额外提取的轨迹特征 Z_{traj}

输出： 经过时空融合的群体关联特征 Z_{st}

过程：


步骤 1：双分支并行提取单模态特征

- 空间分支：通过多头注意力（Multi-head Attention）和多层感知机（MLP），捕捉人物间的静态关联。
- 时间分支：通过Conv-BN-ReLU即卷积+归一化+激活，捕捉人物间的动态关联。

步骤 2：跨模态融合与注意力强化

将空间分支和时间分支的输出拼接，通过交叉注意力，强化“空间 + 时间共同满足群体条件”的关联。

C.边缘分类器



设计目标： 将时空 Transformer提取的个体特征转化为分类图 $G=(V, E)$ 中个体对 (u, v) 的关联分数 $C_{u,v}$ ，判断个体间是否有关联，最终为群体检测提供决策依据。

核心思路：

- 聚焦“感兴趣的边”，仅对图中可能存在群体关联的边进行分类；
- 利用个体的外观 + 轨迹特征构建边特征，通过特征差异量化群体关联可能性；
- 结合时间维度的全局信息，提升分类鲁棒性。

输入： 经多层 STT 模块处理后的个体特征，包括不同深度的外观特征和轨迹特征。

输出： 个体对 (u,v) 的关联分数 $C_{u,v}$ ，用于判断两者是否属于同一群体，分数越高，关联越强。

过程：

步骤1：构建完整个体特征

拼接所有 STT 模块输出的外观和轨迹特征，形成包含全时空信息的个体特征 Z_{all} 。

$$Z_{all} = Z_{app1} \oplus \dots \oplus Z_{appM} \oplus Z_{traj1} \oplus \dots \oplus Z_{trajM}.$$

步骤2：生成边特征

对任意个体对 (u,v) ，通过计算**特征绝对差**构建边特征，量化两者的时空差异，差异越小，表明两者在外观和轨迹上越相似，群体关联可能性越高。

$$F_{(u,v)} = |Z_{all}^u - Z_{all}^v|.$$

步骤3：分类与分数聚合

生成逐帧的分类逻辑值；沿时间维度应用全局平均池化以获得整体预测。

$$R_{u,v} = \text{MLP}_R(F_{u,v}), \quad c_{u,v} = \frac{1}{T} \sum_{t=1}^T R_{u,v}^t,$$

其他问题

1.怎么使模型学会识别群体？

- a) 视频里大多数人无关系（负样本），少数人是有关系（正样本）；
- b) 用专门的损失函数：给正样本和负样本分配不同权重，避免模型只认多数的负样本，学不会认正样本。

2.训练好的模型怎么实际用？

- a) 先筛掉肯定没有关系的：比如离得太远的人、很少同时出现的人，直接排除。
- b) 剩下的人算关系分：用模型算出每对有关联的人的分数，再用聚类算法把分数高的人归成一群。

3.其他

- 用什么网络提取特征（ResNet50），特征有多少维度（16384 维）；
- 训练时学多久，学习率怎么调（在大规模数据集上，模型训练200 个 epochs，学习率在 50、100 和 150 个 epochs 时下降5 倍。在小规模数据集上，模型训练 20 个 epochs，不进行学习率衰减）；
- 判断“离得远不远”“同时出现够不够”的具体阈值（大规模场景严一点，小规模松一点）；
- 用什么硬件训练（RTX 2080 Ti 显卡），练多久（PANDA 数据集 20 小时，JRDB数据集大约需要3小时）。

05

其他收获

...

05 数据集

• Panda数据集

是一个用于大规模群体检测研究的数据集。它具有广阔的视野（可达 1 平方千米）和密集的人群（每帧多达 4000 个对象），包含 9 个用于群体检测的视频。数据集中提供了丰富的标注信息，如边界框、细粒度标签、轨迹和交互信息等。在实验中，8 个视频作为训练集，1 个视频作为测试集。平均每个训练视频有 2713 帧和 1070.4k 个边界框，测试视频有 3500 帧和 335.2k 个边界框。训练和测试视频集中，平均每组视频的大小分别为 144.6 和 75。

• JRDB数据集

全称是 Jack Rabbit Dataset and Benchmark，是一个用于机器人视觉感知研究的数据集。数据采集自社交移动机器人 Jack Rabbit，包含 64 分钟的多模态传感器数据，如 360° 圆柱 RGB 视频、3D 点云、音频信号等。该数据集涵盖室内和室外场景，从机器人的视角进行采集，具有多个遮挡的场景。数据集中包含超过 240 万个边界框注释、180 万个 3D 边界框注释、280 万个个体动作标签、社交活动标签、60 万个身体姿态注释等。在实验中，20 个视频作为训练集，7 个视频作为测试集，使用关键帧（每 15 帧采样一次）来验证群体检测的性能。

05 评价指标

- F1 分数

(1) Precision（精确率）：被认为正的样本中，实际上有多少是正的。

$$\text{Precision} = \frac{TP}{TP + FP}.$$

(2) Recall（召回率）：原本为正的样本中，有多少被找出来了。

$$\text{Recall} = \frac{TP}{TP + FN}.$$

F1分数 (F1-Score)，是分类问题的一个衡量指标，用于权衡Precision和Recall，被定义为精确率和召回率的调和平均数。

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

F1分数 (F1-Score)，是分类问题的一个衡量指标，用于权衡Precision和Recall，被定义为精确率和召回率的调和平均数。

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

a) Micro-F1 (微观F1)

(1) 先计算出所有类别的总的Precision和Recall:

$$\text{Precision}_{micro} = \frac{\sum_{i=1}^n \text{TP}_i}{\sum_{i=1}^n \text{TP}_i + \sum_{i=1}^n \text{FP}_i}.$$

$$\text{Recall}_{micro} = \frac{\sum_{i=1}^n \text{TP}_i}{\sum_{i=1}^n \text{TP}_i + \sum_{i=1}^n \text{FN}_i}.$$

(2) 然后利用F1计算公式计算出来的F1值即为Micro-F1:

$$F1_{micro} = 2 \cdot \frac{\text{Precision}_{micro} \cdot \text{Recall}_{micro}}{\text{Precision}_{micro} + \text{Recall}_{micro}}.$$

因为其考虑了各种类别的数量，所以更适用于数据分布不平衡的情况。在这种情况下，数量较多的类别对F1的影响会较大。

F1分数 (F1-Score)，是分类问题的一个衡量指标，用于权衡Precision和Recall，被定义为精确率和召回率的调和平均数。

b) Macro-F1 (宏观F1)

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

(1) 对各类别的Precision和Recall求平均:

$$\text{Precision}_{macro} = \frac{\sum_{i=1}^n \text{Precision}_i}{n}.$$

$$\text{Recall}_{macro} = \frac{\sum_{i=1}^n \text{Recall}_i}{n}.$$

(2) 然后利用F1计算公式计算出来的F1值即为Macro-F1。

$$F1_{macro} = 2 \cdot \frac{\text{Precision}_{macro} \cdot \text{Recall}_{macro}}{\text{Precision}_{macro} + \text{Recall}_{macro}}.$$

由于对各类别的Precision和Recall求了平均，所以并没有考虑到数据数量的问题。在这种情况下，Precision和Recall较高的类别对F1的影响会较大。

宏平均F1分数

$$\text{Macro-F1} = \frac{1}{n} \sum_{i=1}^n F1_i$$

- **半度量 (half metric)** 是用于评估群体检测模型性能的指标。它通过计算检测到的群体与真实群体之间的交并比 (IoU)，来判断检测结果是否准确。具体而言，当检测群体与真实群体的交集数量，超过两者中较大群体规模的一半时，该检测结果被视为正确检测（阳性样本）。

$$\frac{|Gp_{det} \cap Gp_{gt}|}{\max(|Gp_{det}|, |Gp_{gt}|)} > 0.5,$$

基于此，进一步计算精确率 (Precision)、召回率 (Recall) 和 F1 分数 (F1-score)。

感谢观看

Thanks!

